INTEGRASI INDOBERTWEET DENGAN YOUTUBE API V3 UNTUK MODERASI PROAKTIF KOMENTAR JUDI ONLINE BERBASIS REAL-TIME

PROPOSAL SKRIPSI

Diajukan Sebagai Salah Satu Syarat Untuk Menempuh Mata Kuliah Skripsi

Pada Program Studi Sarjana Terapan Teknik Informatika

Oleh:

Nama : Filamsi Mabda Ghifary

NIM : 22090002

PROGRAM STUDI SARJANA TERAPAN TEKNIK INFORMATIKA

UNIVERSITAS HARKAT NEGERI

TEGAL

2026

UNIVERSITAS HARKAT NEGERI	Kode/No :
	Tanggal :
FORMULIR LEMBAR PERSETUJUAN PROPOSAL SKRIPSI	Revisi :
	SEKOLAH VOKASI

HALAMAN PERSETUJUAN

PROPOSAL TUGAS AKHIR

INTEGRASI MODEL INDOBERTWEET DENGAN YOUTUBE API V3 UNTUK MODERASI PROAKTIF KOMENTAR JUDI ONLINE BERBASIS REAL-TIME

Sebagai Salah Satu Syarat Untuk Menempuh Mata Kuliah Skripsi
Pada Program Studi Sarjana Terapan Teknik Informatika

Oleh:
Nama : Filamsi Mabda Ghifary
NIM : 22090002

Tegal, 26 Februari 2026
Menyetujui,
Penilai Proposal

Penilai I,	Penilai II,
Dwi Intan Af'Idah, S.T., M.Kom.	Arif Hidayah, S.Tr.Kom., M.Tr.Kom.
NIPY. 11.020.470	NIPY. 10.024.548

Universitas Harkat Negeri

DAFTAR ISI

HALAMAN PERSETUJUAN ii

DAFTAR ISI iii

DAFTAR TABEL vi

DAFTAR GAMBAR vii

1. JUDUL 1

2. PENDAHULUAN 1

   a. Latar Belakang Masalah 1

   b. Rumusan Masalah 4

   c. Batasan Masalah 5

   d. Tujuan Penelitian 5

   e. Manfaat Penelitian 6

3. TINJAUAN PUSTAKA 7

   a. Youtube dan Moderasi Konten 7

   b. Komentar Judi Online sebagai Ancaman Digital 7

   c. Pemrosesan Bahasa Alami (*Natural Language Processing* - NLP) 8

   d. Model BERT & IndoBERTweet 9

   e. YouTube Data API v3 dalam Riset Computer Science (Integrasi Moderasi) 10

   f. Penelitian Terkait (Gap Penelitian) 11

4. LANDASAN TEORI 13

   a. YouTube, Komentar, dan Judi Online 13

      1) Kolom Komentar YouTube sebagai Ruang Interaksi 14

      2) Konsep Judi Online dalam Perspektif Hukum Indonesia 15

3) Komentar Promosi Judi Online di YouTube 16

4) Spam Komentar, *Obfuscation*, dan Tantangan Moderasi 18

b. Pemrosesan Bahasa Alami (*Natural Language Processing* - NLP) dan Klasifikasi Teks 19

1) Konsep Dasar Pemrosesan Bahasa Alami 19

2) Tahapan Praproses Teks dalam NLP 20

3) Representasi Teks 21

4) Klasifikasi Teks pada Komentar Media Sosial 22

5) Metrik Evaluasi Kinerja Model Klasifikasi 23

c. Arsitektur Transformer dan Model BERT 24

1) Konsep Dasar Arsitektur Transformer 24

2) Pengertian BERT (Bidirectional Encoder Representations from Transformers) 26

3) Proses *Pre-training* dan *Fine-tuning* BERT untuk Klasifikasi Teks 27

4) Model BERT untuk Bahasa Indonesia (IndoBERT dan IndoBERTweet) 28

5) Kelebihan BERT dalam Menangani Teks Komentar yang Beragam dan Mengandung *Obfuscation* 29

d. YouTube Data API v3 untuk Moderasi Komentar 31

1) Konsep API dan Endpoint untuk Moderasi Komentar (ambil komentar & ubah status moderasi) 31

2) OAuth 2.0 untuk Otorisasi Kanal (Channel Authorization) 32

3) Kuota/Rate Limit dan Dampaknya ke Desain Sistem Moderasi 33

e. Teknologi Implementasi Sistem Moderasi 35

1) Python 35

2) HuggingFace Transformers 36

3) *PyTorch*/TensorFlow (konsep training/inference) 38

4) Pandas/NumPy (olah data) 39
5) Scikit-learn (split, metrik evaluasi) 40
6) Postman + Colab/Jupyter/VS Code 41
5. METODOLOGI PENELITIAN 42
a. Bahan Penelitian 42
b. Alat Penelitian 43
c. Alur Penelitian 44
6. JADWAL PENELITIAN 47
7. DAFTAR PUSTAKA 50
8. LAMPIRAN 54

DAFTAR TABEL

Tabel 1 Gap Penelitian 13
Tabel 2 Jadwal Penelitian..... 50

DAFTAR GAMBAR

Gambar 1 Alur Proses Moderasi 54
Gambar 2 Arsitektur Sistem 54
Gambar 3 Use Case Diagram 55
Gambar 4 AD - 1 Otorisasi Akses Youtube 56
Gambar 5 AD – 2 Kelola Target Pemantauan 56
Gambar 6 AD – 3 Kelola Threshold 56
Gambar 7 AD – 4 Pantau dan ambil komentar (Near Real-time) 57
Gambar 8 AD - 5 Evaluasi Komentar (scoring & policy) 57
Gambar 9 AD - 6 Terapkan Status Moderasi (Publish,Hold,Reject) 58
Gambar 10 AD - 8 Monitoring di Dashboard (Daftar komentar & status) 58
Gambar 11 AD - 9 Lihat Detail Komentar 59
Gambar 12 AD - 10 Lihat Audit Log (Riwayat aksi) 59
Gambar 13 SD-1 Otorisasi Akses YouTube (OAuth2) 60
Gambar 14 SD-2 Kelola Target Pemantauan (Kanal,Video,Filter) 60
Gambar 15 SD-3 Pantau dan Ambil Komentar (Near real-time) 61
Gambar 16 SD-4 Evaluasi Komentar (Scoring & Policy) 61
Gambar 17 SD-5 Terapkan Status Moderasi (Publish,Hold,Reject) 62
Gambar 18 SD-6 Review Komentar Borderline (Human-in-the-loop) 62
Gambar 19 SD-7 Monitoring di Dashboard (Daftar komentar & status) 62
Gambar 20 SD-8 Lihat Detail Komentar (teks, skor, keputusan) 63
Gambar 21 SD-9 Kelola Threshold dan Model 63
Gambar 22 SD-10 Lihat Audit Log (Riwayat aksi) 64
Gambar 23 Class Diagram 65
Gambar 24 Desain Database 65
Gambar 25 UI/UX Login Page 65
Gambar 26 UI/UX Pilih Kanal 66
Gambar 27 UI/UX Verifikasi Izin 66
Gambar 28 UI/UX Dashboard 67
Gambar 29 UI/UX Halaman Moderasi 67
Gambar 30 UI/UX Halaman Riwayat 68

Gambar 31 UI/UX Halaman Pengaturan 69

1. JUDUL

INTEGRASI MODEL INDOBERTWEET DENGAN YOUTUBE API V3 UNTUK MODERASI PROAKTIF KOMENTAR JUDI ONLINE BERBASIS REAL-TIME

2. PENDAHULUAN

a. Latar Belakang Masalah

YouTube telah berkembang menjadi salah satu *platform* berbagi video terbesar di dunia, dengan estimasi lebih dari 2,5 miliar *monthly active users* pada tahun 2025. Angka ini menempatkan YouTube sebagai salah satu destinasi digital paling dominan secara global [1], didukung pula oleh ringkasan *global overview* DataReportal 2025 [2]. Di Indonesia, adopsi media sosial sangat tinggi DataReportal melaporkan ±139 juta pengguna media sosial pada Januari 2024 (≈49,9% populasi) [3]. Untuk *YouTube* secara spesifik, *ad reach* di Indonesia tercatat besar dan cenderung stabil pada kuartal terakhir 2024 hingga Januari 2025 [4]. Skala masif ini menciptakan peluang distribusi informasi yang luas, namun sekaligus memunculkan tantangan serius dalam menjaga kualitas interaksi di kolom komentar.

Salah satu tantangan yang kian menonjol adalah maraknya komentar *spam* yang mempromosikan *online gambling* pada video-video populer. Komentar seperti ini bukan hanya mengganggu kenyamanan, namun juga berpotensi menyesatkan pengguna terutama remaja dan dewasa muda dan bertentangan langsung dengan *YouTube Community Guidelines* terkait *spam/deceptive practices & scams* [5]. Dalam konteks Indonesia, isu promosi *online gambling* juga bersinggungan dengan kepatuhan regulasi lokal, sehingga mitigasinya menjadi kebutuhan mendesak dari perspektif *platform* maupun pembuat konten.

Moderasi manual pada skala jutaan komentar per hari tidak lagi efektif: biaya waktu dan sumber daya manusia sangat tinggi, sementara kecepatan penyebaran *spam* menuntut respons yang hampir *real-time*. Dengan demikian,

dibutuhkan sistem moderasi otomatis yang akurat, responsif, selaras dengan kebijakan *platform*, serta cukup adaptif terhadap dinamika taktik *Spammer* seperti ejaan diacak, penyamaran tautan, atau penggunaan istilah kode.

Kemajuan di bidang *Natural Language Processing (NLP)* khususnya model berbasis *Transformer* membuka peluang baru. *BERT (Bidirectional Encoder Representations from Transformers)* menunjukkan performa unggul dalam beragam tugas klasifikasi teks karena kemampuannya memahami konteks dua arah pada tingkat token dan kalimat [6]. Tinjauan dan studi terbaru juga menegaskan keunggulan pendekatan berbasis *Transformer* dibanding pendekatan konvensional ketika pemahaman konteks lebih kaya dibutuhkan, termasuk pada deteksi *spam* tersamarkan di media sosial [7] [8]. Secara lebih spesifik, riset mutakhir menunjukkan model berbasis *Transformer* efektif mendeteksi indikasi perilaku terkait judi dari teks daring dengan akurasi tinggi pada skenario terkontrol [9] . Walau konteks data studi tersebut berbeda dari komentar YouTube, temuan ini menjadi sinyal kuat bahwa pendekatan berbasis representasi kontekstual seperti *BERT* berpotensi diadaptasikan untuk domain komentar *platform* video.

Dari sisi integrasi sistem, *YouTube Data API v3* menyediakan antarmuka untuk mengambil, menganalisis, dan memoderasi komentar. *Endpoint* seperti *commentThreads.list* memfasilitasi pengambilan komentar, sementara *comments.setModerationStatus* memungkinkan perubahan status (menahan, menolak, atau mempublikasikan) pada komentar tertentu [10] [11]. Kombinasi *pipeline NLP* (berbasis *BERT*) dengan API resmi *platform* membuka jalan bagi moderasi proaktif, yakni deteksi–tindak otomatis sesegera mungkin setelah komentar diposting.

Untuk dapat mengakses data komentar dari akun YouTube pengguna secara aman, sistem memanfaatkan mekanisme autentikasi OAuth 2.0 yang disediakan oleh Google. Melalui mekanisme ini, pengguna cukup melakukan login menggunakan akun Google dan memberikan izin akses terhadap data YouTube miliknya tanpa perlu melakukan konfigurasi API secara manual seperti pembuatan client ID atau pengaturan proyek Google Cloud secara mandiri.

Setelah pengguna memberikan persetujuan (user consent), sistem akan memperoleh access token yang digunakan untuk memanggil YouTube Data API v3 guna mengambil daftar kanal, video, serta komentar yang akan dianalisis. Pendekatan ini memungkinkan integrasi sistem moderasi dilakukan secara lebih praktis, aman, dan terpusat [12].

Namun, moderasi berbasis AI bukan tanpa risiko. Kasus keliru-tandai (*false positive*) dapat terjadi ketika konteks tidak dipahami dengan baik contohnya insiden diskusi "catur" yang sempat terklasifikasi sebagai ujaran kebencian pada sistem moderasi otomatis [13]. Insiden semacam ini menegaskan pentingnya pendekatan yang sensitif konteks, kalibrasi ambang keputusan, serta skema *human-in-the-loop* untuk kasus *borderline*.

Di sisi lain, karakteristik komentar promosi *online gambling* kerap melibatkan *Obfuscation* (*leetspeak*: "g4c0r", spasi antar huruf "s l o t", atau pemotongan URL), campuran bahasa Indonesia–Inggris, dan pola pemasaran terselubung. Pendekatan lama berbasis *RNN* atau *CNN* memang bermanfaat, tetapi memiliki keterbatasan dalam menangkap *long-range dependency* dan nuansa konteks halus pada bahasa sehari-hari di kolom komentar [14]. *BERT*, dengan perhatian dua arah, menawarkan representasi kontekstual yang lebih kaya sehingga lebih tepat untuk tantangan ini [6] [7].

Penelitian terkait pada ranah YouTube juga menyoroti pendekatan deteksi *spam* berbasis perilaku pengguna (frekuensi komentar, waktu posting, atau pola pengulangan), seperti yang diusulkan pada studi komparatif *machine learning* untuk komentar YouTube [8]. Meski berguna, pendekatan tersebut cenderung kurang efektif menangani promosi judi yang "rapi" secara sintaksis namun tersamar secara semantik. Karena itu, pendekatan berbasis konten (*content-based*) melalui *NLP* modern dibutuhkan untuk melengkapi indikator perilaku.

Dalam penelitian ini, pendekatan yang digunakan untuk mendeteksi komentar judi online adalah model berbasis transformer berbahasa Indonesia, yaitu IndoBERTweet. IndoBERTweet merupakan pengembangan dari arsitektur BERT yang telah dilatih menggunakan korpus data media sosial berbahasa Indonesia, khususnya Twitter, sehingga lebih mampu menangani karakteristik

teks informal yang umum ditemukan pada platform media sosial. Dibandingkan dengan metode klasifikasi tradisional seperti Naïve Bayes atau Support Vector Machine (SVM), model berbasis transformer seperti IndoBERTweet memiliki kemampuan memahami konteks kalimat secara lebih mendalam melalui mekanisme pemodelan konteks dua arah (bidirectional context).

Keunggulan utama IndoBERTweet terletak pada kemampuannya memahami variasi bahasa informal yang sering muncul pada komentar daring, seperti penggunaan slang, singkatan, maupun teknik penyamaran kata (obfuscation) seperti *leetspeak*, pemisahan huruf, atau penyamaran tautan. Karakteristik tersebut sangat umum ditemukan pada komentar promosi judi online di platform YouTube yang berupaya menghindari sistem moderasi otomatis. Dengan memanfaatkan IndoBERTweet, sistem diharapkan mampu melakukan klasifikasi komentar secara lebih akurat serta adaptif terhadap berbagai pola penulisan yang tidak terstruktur.

Selain itu, integrasi model IndoBERTweet dengan YouTube Data API v3 memungkinkan proses pengambilan dan analisis komentar dilakukan secara near real-time. Melalui integrasi tersebut, komentar yang teridentifikasi sebagai spam atau promosi judi online dapat segera direkomendasikan untuk dimoderasi oleh pemilik kanal. Kombinasi antara pemrosesan bahasa alami berbasis transformer dan integrasi API platform ini menjadi pendekatan yang relevan untuk mendukung sistem moderasi komentar yang lebih proaktif dan efisien dibandingkan metode moderasi manual.

Pada akhirnya, diharapkan sistem ini mampu meningkatkan efisiensi penyaringan komentar, menurunkan paparan promosi judi, dan menjaga ekosistem digital yang lebih sehat tanpa mengorbankan kebebasan berekspresi yang sah serta menyediakan fondasi empiris bagi pengembangan kebijakan moderasi yang lebih adaptif dan transparan di masa depan.

b. Rumusan Masalah

1. Bagaimana mengintegrasikan model IndoBERTweet dengan YouTube Data API v3 untuk mendeteksi komentar judi online secara otomatis?

2. Bagaimana merancang sistem moderasi komentar berbasis real-time pada platform YouTube?
3. Seberapa efektif sistem moderasi proaktif yang diusulkan dibanding metode moderasi konvensional, ditinjau dari *Precision*, *Recall*, *F1-score*, *PR-AUC*, dan waktu respons?
4. Apa saja tantangan teknis dan operasional (*Obfuscation* teks, campuran bahasa, dan batasan kuota/otorisasi API) serta bagaimana strategi mitigasinya?

c. Batasan Masalah

1. Jenis konten yang dimoderasi fokus pada komentar yang mengandung unsur promosi *online gambling* di YouTube.
2. Sumber data komentar dari YouTube menggunakan *YouTube Data API v3*; tidak mencakup *platform* lain.
3. Model hanya menggunakan IndoBERTweet model lain (*GPT*, *RNN*, *CNN*) tidak diperbandingkan.
4. Hak dan otorisasi aksi moderasi (*comments.setModerationStatus*) hanya pada kanal milik peneliti/mitra dengan otorisasi *OAuth* yang sesuai [11].
5. Skala pengujian memprioritaskan video/kanal dengan volume komentar besar.
6. Format data fokus pada teks komentar (termasuk *emoji*/URL) sebagai token teks. konten non-teks tidak dibahas.
7. Evaluasi sistem terbatas pada akurasi, *Precision*, *Recall*, *F1-score, PR-AUC* dan waktu respons. Tidak mengeksplorasi aspek psikologis atau sosial.
8. Waktu pengujian 1–3 bulan pasca implementasi.

d. Tujuan Penelitian

1. Merancang dan mengimplementasikan model deteksi komentar promosi *online gambling* berbasis IndoBERTweet pada domain komentar YouTube.
2. Mengembangkan integrasi teknis antara IndoBERTweet dan *YouTube Data API v3* untuk moderasi komentar otomatis berbasis *near real-time*.
3. Mengevaluasi kinerja sistem (*Accuracy*, *Precision*, *Recall*, *F1-score, PR-*

AUC dan waktu respons).

4. Mengidentifikasi potensi tantangan dan solusi dalam penerapan sistem moderasi otomatis berbasis *AI* di *platform* video digital.

e. Manfaat Penelitian

1. Manfaat bagi *Content Creator*
    - Beban moderasi turun karena komentar promosi judi otomatis ditahan/ditolak melalui integrasi IndoBERTweet + *YouTube Data API v3*.
    - Kebersihan kolom komentar meningkat, menjaga brand *safety* dan kepercayaan audiens.
    - Waktu respons moderasi lebih cepat (mendekati *real-time*) tanpa harus memeriksa komentar satu per satu.
2. Manfaat bagi Pengguna YouTube
    - Pengalaman menonton lebih aman & nyaman karena paparan tautan/ajakan judi berkurang drastis.
    - Risiko misinformasi/penipuan berkurang, khususnya bagi remaja/dewasa muda.
    - Kualitas diskusi meningkat karena *spam* berkurang, memudahkan interaksi yang sehat dan *on-topic*.
3. Manfaat bagi Kampus atau Pendidikan
    - Kontribusi ilmiah pada NLP terapan: studi kasus moderasi proaktif komentar YouTube berbahasa Indonesia dengan tantangan obfusikasi (*leetspeak*, spasi antar huruf, URL tersamar).
    - Artefak riset *pipeline* praproses *anti-Obfuscation*, model *fine-tuned* (IndoBERT/IndoBERTweet), serta evaluasi dengan metrik yang tepat (PR-AUC, F1 per kelas) pada data *in-domain*.
    - Sarana pembelajaran: dapat dijadikan bahan praktikum/topik Tugas
4. Manfaat bagi Industri
    - Blueprint teknis moderasi proaktif yang *deployable*: kombinasi model Transformer + kebijakan moderasi + integrasi API.

- Praktik terbaik operasional: kalibrasi *threshold*, penanganan kuota API, *logging*, serta *fail-safe* (fall back ke manual review).
- Dampak keamanan platform: pengurangan penyebaran konten ilegal (judi) tanpa mengorbankan kebebasan berekspresi yang sah.

Peluang adopsi: dapat diadaptasi ke domain lain (marketplace, forum, live chat) dengan penyesuaian label & kamus obfusikasi.

3. TINJAUAN PUSTAKA

a. Youtube dan Moderasi Konten

Pada ranah ilmiah *computer science*, penelitian deteksi *spam* komentar YouTube banyak menekankan kebutuhan moderasi berbasis *machine learning* karena volume dan kecepatan aliran komentar yang tinggi. Studi komparatif tingkat *model* pada komentar YouTube menunjukkan bahwa pendekatan *machine learning* modern (termasuk *ensembles*) unggul terhadap *baseline* sederhana, sekaligus menandai pentingnya desain fitur dan *evaluation protocol* yang ketat [8].

Selain itu, di jurnal *Electrical & Computer Engineering* menegaskan bahwa *hybrid deep learning* dapat meningkatkan ketepatan deteksi *spam* komentar YouTube dengan menggabungkan kekuatan *sequence modeling* dan representasi teks, serta relevan untuk *deployment* moderasi *near real-time*. Temuan ini memberi landasan teknis bahwa moderasi otomatis yang efektif tidak hanya menandai komentar, namun juga membantu menjaga kebersihan ruang diskusi publik secara berkelanjutan [15]

Penelitian-penelitian tersebut memperlihatkan arah solutif moderasi di YouTube yang memadukan *content-based filtering* dengan *automation pipeline*, meskipun tantangan konteks semantik dan *Obfuscation* masih sering menyebabkan *false negatives* mendorong adopsi *NLP* yang lebih kontekstual [8] [15].

b. Komentar Judi Online sebagai Ancaman Digital

Pada domain *spam* bertema judi, taktik *Obfuscation* seperti *leetspeak*

(“g4c0r”), pemisahan huruf (“s l o t”), dan pemotongan URL kerap membuat pola *rule-based* gagal menangkap makna. Literatur *computer science* terkini menegaskan bahwa representasi kontekstual alih-alih sekadar pola permukaan lebih tangguh memodelkan variasi penyamaran di *social media* . Dengan *RNN_BERT-based* untuk *text classification*, mereka menunjukkan penguatan akurasi pada data berbahasa alami yang sarat nuansa konteks, sebuah indikator bahwa *context-aware features* penting untuk mendeteksi promosi judi yang tersamar [16].

Di sisi lain, kajian komparatif *Machine Learning* untuk komentar YouTube memperlihatkan efektivitas fitur perilaku dan *classical models* untuk *spam* umum; namun pendekatan ini cenderung kurang andal ketika *semantic camouflage* digunakan secara sistematis oleh *Spammer*. Hal tersebut memperkuat kebutuhan *content-based* NLP berbasis *Transformer* untuk mengidentifikasi indikasi promosi judi yang “rapi” secara sintaksis namun bermakna promosi secara semantik [8].

c. Pemrosesan Bahasa Alami (*Natural Language Processing* - NLP)

Teknik NLP umum *Tokenization*, *Stopword Removal*, *Stemming/lemmatization*, *TF-IDF*, dan *Word embeddings* telah lama menjadi fondasi klasifikasi teks. *Survey* komparatif di jurnal *Indonesian Journal of Electrical Engineering and Computer Science* merangkum performa beragam arsitektur *deep learning* untuk klasifikasi teks, menyoroti kelebihan dan keterbatasan *CNN* dan *RNN* dibanding pendekatan terbaru. Ringkasan ini berguna sebagai pijakan metodologis sekalipun banyak studi terbaru telah beralih ke *Transformer* untuk pemahaman konteks yang lebih kaya [14].

Di konteks Indonesia, ketersediaan *benchmark* dan *pretrained model* berbahasa Indonesia seperti *IndoLEM* dan *IndoBERT* mempermudah adopsi *NLP* modern dalam tugas klasifikasi komentar. Keberadaan *IndoBERT* yang di-*pretrain* pada korpus Indonesia menjadikannya kandidat kuat untuk *fine-tuning* deteksi komentar promosi judi di YouTube [17].

d. Model BERT & IndoBERTweet

Bidirectional Encoder Representations from Transformers (BERT) merupakan model berbasis arsitektur Transformer yang mampu memahami konteks bahasa secara dua arah (bidirectional). Berbeda dengan model bahasa tradisional yang membaca teks secara sekuensial dari kiri ke kanan atau sebaliknya, BERT mempelajari hubungan konteks dari kedua arah secara bersamaan sehingga mampu menghasilkan representasi makna kata yang lebih akurat dalam sebuah kalimat. Pendekatan ini terbukti efektif pada berbagai tugas pemrosesan bahasa alami seperti klasifikasi teks, analisis sentimen, dan deteksi spam. [9].

Di sisi arsitektural, penggabungan BERT *embeddings* dengan jaringan berurutan (*RNN_BERT-based*) dapat menaikkan akurasi klasifikasi pada teks berkonteks kompleks. Untuk kasus YouTube, pendekatan hibrida demikian berpotensi dimanfaatkan pada *ablation study* sebagai pembanding *BERT fine-tuning* murni [16].

Untuk tugas pemrosesan bahasa alami berbahasa Indonesia, penggunaan model BERT yang dilatih pada korpus bahasa Inggris sering kali kurang optimal karena perbedaan kosakata, struktur bahasa, serta variasi penggunaan bahasa informal. Oleh karena itu, dikembangkan berbagai varian BERT yang dilatih khusus menggunakan korpus bahasa Indonesia. Salah satu di antaranya adalah IndoBERTweet, yaitu model berbasis arsitektur BERT yang dirancang untuk memahami teks media sosial berbahasa Indonesia. IndoBERTweet dilatih menggunakan kumpulan data besar dari platform Twitter sehingga mampu menangkap karakteristik bahasa informal yang umum ditemukan pada komunikasi daring, seperti penggunaan slang, singkatan, maupun variasi ejaan.

Model IndoBERTweet merupakan pengembangan dari keluarga model BERT berbahasa Indonesia yang dikembangkan oleh Koto dkk. dalam kerangka benchmark IndoLEM. Berbagai penelitian menunjukkan bahwa model berbasis BERT berbahasa Indonesia mampu mencapai performa yang tinggi pada berbagai tugas pemrosesan bahasa alami seperti klasifikasi teks, part-of-speech tagging, named entity recognition, dan dependency parsing [18].

Keunggulan IndoBERTweet terletak pada kemampuannya dalam memahami variasi bahasa tidak formal yang sering muncul pada media sosial. Hal ini menjadi penting dalam konteks penelitian ini karena komentar promosi judi online di platform YouTube sering menggunakan berbagai teknik penyamaran kata (obfuscation) untuk menghindari sistem moderasi otomatis, seperti penggunaan leetspeak, pemisahan huruf, maupun penyamaran tautan. Dengan karakteristik pelatihan yang berfokus pada teks media sosial, IndoBERTweet dinilai lebih sesuai untuk menangani pola bahasa yang muncul pada komentar pengguna di platform digital [18].

Dalam penelitian ini, IndoBERTweet digunakan sebagai model dasar (backbone) yang akan di-fine-tune menggunakan dataset komentar YouTube berbahasa Indonesia yang telah dilabeli sebagai komentar promosi judi dan non-judi. Proses fine-tuning memungkinkan model yang telah dilatih sebelumnya pada korpus besar dapat beradaptasi dengan tugas klasifikasi spesifik secara lebih efisien tanpa perlu melatih model dari awal. Dengan pendekatan ini, diharapkan sistem mampu mendeteksi komentar promosi judi online secara lebih akurat dan adaptif terhadap berbagai pola penulisan yang muncul pada kolom komentar YouTube.

e. YouTube Data API v3 dalam Riset Computer Science (Integrasi Moderasi)

Rangkaian artikel *computer science* tentang *spam* komentar YouTube menempatkan integrasi *model* dengan *pipeline* moderasi sebagai langkah krusial agar temuan klasifikasi berdampak operasional. Studi IJECE *(Internasional Journal of Electrical and Computer Engineering)* menekankan implikasi *real-time moderation* dengan rancangan *hybrid Deep learning* khusus komentar YouTube, sedangkan studi komparatif yang dilakukan oleh Airlangga membahas *pipeline* dari *preprocessing* hingga evaluasi, relevan untuk *end-to-end* integrasi [15] [8] .

f. Penelitian Terkait (Gap Penelitian)

Studi	Inti (Masalah – Tujuan – Metode – Hasil)	Gap & Relevansi dengan Skripsi
Zulqarnain dkk., 2020	- Masalah: variasi akurasi klasifikasi teks. - Tujuan: *review* model *deep learning*. - Metode: komparatif *CNN*, *RNN/LSTM*, *DBN* - Hasil: *RNN/LSTM cenderung lebih baik dalam menangani dependensi sekuensial dibanding CNN pada beberapa dataset*	- Tidak spesifik *spam/judi* YouTube. - bersifat *review model deep learning*. - Belum menggunakan arsitektur Transformer modern.
Smith, Reiter, & Peters, 2023	- Masalah: deteksi tanda perilaku judi. - Tujuan: uji efektivitas *Transformer/LLM*. - Metode: klasifikasi teks forum *online*. - Hasil: BERT menunjukkan performaklasifikasi memuaskan ketika dilatih dengan anotasi manual berbasis kriteria diagnostik, bahkan pada data terbatas	- Domain forum online bukan komentar YouTube. - belum membahas *Obfuscation* Indonesia. → Perlu validasi *in-domain* + strategi anti-*Obfuscation*.
Eang & Lee, 2024	- Masalah: akurasi saat konteks kompleks. - Tujuan: arsitektur hibrida. - Metode: *BERT* + *RNN* (*RNN_BERT-based*). - Hasil: akurasi naik vs *baseline* pada *text classification*.	- Tidak spesifik *spam/judi.* - Tanpa integrasi API.
IJECE, 2024	- Masalah: *spam* komentar YouTube. - Tujuan: *hybrid deep learning*. - Metode: *hybrid DL* untuk deteksi *spam* komentar. - Hasil: model efektif untuk deteksi spam dengan akurasi tinggi, berpotensi	Fokus *spam* umum; belum spesifik promosi judi tersamar. → Perlu *content-based* yang lebih kontekstual.

Studi	Inti (Masalah – Tujuan – Metode – Hasil)	Gap & Relevansi dengan Skripsi
	digunakan dalam sistem moderasi near real-time.	
Airlangga, 2024	- Masalah: *spam* komentar YouTube. - Tujuan: komparasi model. - Metode: *ML* tradisional & *ensembles*. - Hasil: fitur perilaku + *classical models* efektif pada *spam* umum.	Fokus pada spam umum dengan model ML tradisional; belum mengeksplorasi pemodelan konteks semantik mendalam untuk deteksi promosi judi tersamar berbasis Transformer.
Koto dkk., 2020	- Masalah: kelangkaan *Resources* Indonesia. - Tujuan: rilis *benchmark dataset (INDOLEM)* & *pretrained model (INDoBERT)*. - Metode: Pengembangan benchmark INDOLEM dan pelatihan model monolingual transformer INDOBERT berbasis arsitektur BERT. - Hasil: *IndoBERT* kuat untuk tugas bahasa Indonesia.	- Belum kasus YouTube/judi - Backbone model untuk fine-tuning pada tugas klasifikasi komentar promosi judi di YouTube.
Usulan Skripsi	- Masalah: komentar promosi *online gambling* di YouTube Indonesia sulit dideteksi karena *Obfuscation* (*leetspeak*, spasi antar huruf, pemotongan URL) dan konteks pendek. - Tujuan: membangun sistem moderasi proaktif berbasis IndoBERTweet yang	Mengisi *gap*: (1) Fokus in-domain Indonesia khusus promosi judi, (2) Kuat terhadap *Obfuscation*, (3) integrasi end-to-end

Studi	Inti (Masalah – Tujuan – Metode – Hasil)	Gap & Relevansi dengan Skripsi
	near real-time dan terintegrasi dengan *YouTube Data API v3*. - Metode: (1) Pengambilan komentar via *commentThreads.list*, (2) praproses anti-*Obfuscation* (normalisasi huruf/angka, *URL masking*, *whitespace folding*), (3) *fine-tuning IndoBERT / IndoBERTweet* untuk klasifikasi biner (*gambling* vs *non-gambling*), (4) *threshold calibration* berbasis *PR curve*, (5) *human-in-the-loop* untuk kasus *borderline*, (6) aksi moderasi via *comments.setModerationStatus*. - Hasil (target): *F1-macro* ≥ 0.85 pada data *in-domain.* *Precision* kelas *gambling* ≥ 0.90 pada *operating point* produksi. *latency* moderasi median < 5 detik per komentar pada *prototype*.	dengan API resmi (otomasi moderasi pada kanal berotorisasi), (4) evaluasi offline–online dengan metrik operasional (*F1*, *PR-AUC*, *latency*),

Tabel 1 Gap Penelitian

4. LANDASAN TEORI

a. YouTube, Komentar, dan Judi Online

YouTube adalah platform berbagi video dan jejaring sosial yang

memungkinkan pengguna mengunggah, menonton, memberi komentar, serta berinteraksi melalui berbagai fitur komunitas. Secara global, jumlah pengguna aktif bulanan YouTube diperkirakan melampaui 2,5 miliar pada tahun 2025, sehingga menempatkannya sebagai salah satu destinasi digital terbesar di dunia [1]. Di Indonesia, laporan Digital 2024 dan Digital 2025: Indonesia dari *We Are Social/DataReportal* menunjukkan bahwa ratusan juta pengguna internet dan sekitar separuh populasi Indonesia aktif di media sosial, dengan YouTube termasuk di antara platform yang memiliki jangkauan iklan dan basis pengguna yang sangat besar [2] [3] [4]. Skala masif ini menjadikan YouTube bukan hanya medium hiburan, tetapi juga ruang publik digital tempat informasi, promosi, hingga aktivitas ilegal dapat tersebar dengan sangat cepat.

Sebagai ekosistem, YouTube menyediakan kanal (channel), sistem langganan (*subscribe*), rekomendasi berbasis algoritma, serta fitur interaksi seperti *like, share, community post*, dan kolom komentar. Dokumentasi resmi "*How YouTube works*" menjelaskan bahwa fitur-fitur tersebut dirancang untuk mendukung hubungan jangka panjang antara kreator, penonton, dan pengiklan, dengan tetap diikat oleh kebijakan komunitas yang mengatur keamanan dan kepercayaan di platform. Dengan kata lain, YouTube adalah *socio-technical system* yang mempertemukan dimensi teknis (algoritma, API, infrastruktur) dengan dimensi sosial (norma komunitas, perilaku pengguna, dan regulasi) [5].

1) Kolom Komentar YouTube sebagai Ruang Interaksi

Kolom komentar pada YouTube berfungsi sebagai medium utama interaksi teks antara kreator dan penonton. Melalui komentar, pengguna dapat memberikan umpan balik, bertanya, berdiskusi, maupun membangun komunitas di sekitar sebuah kanal. Penelitian-penelitian di bidang computer science menunjukkan bahwa komentar YouTube bersifat sangat dinamis: jumlahnya dapat mencapai jutaan per kanal dan masuk secara terus-menerus dalam waktu nyata, sehingga menuntut strategi moderasi yang sistematis. Airlangga menekankan bahwa kombinasi volume besar dan beragamnya perilaku pengguna membuat moderasi manual menjadi tidak efisien dan

mendorong penggunaan teknik *machine learning* untuk menyaring komentar spam di YouTube [8].

Dari sisi kebijakan, YouTube menerapkan *Community Guidelines* yang mengatur perilaku di kolom komentar, termasuk larangan spam, penipuan, ujaran kebencian, dan konten berbahaya lainnya. Dalam dokumen resmi "*Spam, deceptive practices, & scams policies*", YouTube menyatakan bahwa platform tidak mengizinkan spam, penipuan, dan praktik menyesatkan yang memanfaatkan komunitas YouTube, termasuk konten yang tujuannya mendorong pengguna meninggalkan YouTube ke situs lain secara menipu [5]. Kebijakan ini menjadi dasar normatif bagi sistem moderasi (baik manual maupun otomatis) untuk menindak komentar yang melanggar, termasuk komentar promosi judi online yang memanfaatkan tautan atau ajakan terselubung.

Seiring berkembangnya platform, YouTube juga menyediakan berbagai alat moderasi seperti *blocked words*, *hold for review*, pemblokiran akun, pelaporan (*report*), serta integrasi API untuk pengelolaan komentar secara terprogram. Dokumentasi YouTube Data API v3 menjelaskan adanya *endpoint* seperti `commentThreads.list` untuk mengambil komentar dan `comments.setModerationStatus` untuk mengubah status moderasi komentar (menahan, menolak, atau mempublikasikan) [10]. Integrasi ini menjadi fondasi teknis bagi penelitian yang mengusulkan moderasi proaktif komentar secara real-time, termasuk pada kasus promosi judi online.

2) Konsep Judi Online dalam Perspektif Hukum Indonesia

Judi online pada dasarnya adalah bentuk perjudian yang dilakukan menggunakan media elektronik atau internet, di mana pihak-pihak yang terlibat mempertaruhkan sejumlah uang atau nilai lain pada suatu permainan atau peristiwa dengan hasil tidak pasti demi memperoleh keuntungan. Sejumlah kajian yuridis menjelaskan bahwa judi online termasuk salah satu bentuk *cyber crime*, yaitu tindak pidana yang memanfaatkan teknologi informasi dan jaringan internet sebagai media utama kejahatan [19].

Dalam konteks hukum Indonesia, larangan perjudian telah lama diatur dalam Kitab Undang-Undang Hukum Pidana (KUHP) pada Pasal 303 dan 303 bis, yang pada dasarnya melarang segala bentuk penyelenggaraan perjudian, baik secara langsung maupun melalui sarana lain [20]. Perkembangan teknologi kemudian mendorong penguatan regulasi melalui Undang-Undang Informasi dan Transaksi Elektronik (UU ITE). Artikel analitis Hukumonline menjelaskan bahwa Pasal 27 ayat (2) jo. Pasal 45 ayat (3) UU No. 1 Tahun 2024 (perubahan UU ITE) mengancam pelaku yang dengan sengaja dan tanpa hak mendistribusikan, mentransmisikan, dan/atau membuat dapat diaksesnya informasi elektronik bermuatan perjudian dengan pidana penjara hingga 10 tahun dan/atau denda hingga Rp10 miliar [21].

Pemerintah Indonesia, melalui Kementerian Komunikasi dan Informatika (Kominfo), menempatkan pemberantasan judi online sebagai salah satu prioritas. Menkominfo beberapa kali menegaskan bahwa judi online merupakan bentuk penipuan (scam) yang menyengsarakan rakyat, bahkan disebut sebagai "penipuan terbesar terhadap rakyat Indonesia" . Selain penindakan hukum terhadap pelaku, Instruksi Menteri Kominfo No. 1 Tahun 2023 serta berbagai program "Sapu Judol" menargetkan pemblokiran konten dan situs judi online, termasuk yang beredar melalui media sosial dan platform seperti YouTube [22].

Dengan demikian, secara normatif, aktivitas judi online termasuk promosi dan ajakan berjudi melalui media digital jelas dikategorikan sebagai tindak pidana. Kolom komentar YouTube yang berisi promosi judi online karenanya bukan sekadar isu teknis spam, tetapi juga terkait langsung dengan kepatuhan terhadap hukum pidana dan kebijakan nasional [22].

3) Komentar Promosi Judi Online di YouTube

Pada tingkat praktik, pelaku judi online memanfaatkan ruang-ruang interaksi publik di internet untuk menyebarkan ajakan dan tautan menuju situs atau aplikasi judi. Kolom komentar YouTube menjadi salah satu sasaran utama karena sifatnya yang terbuka, volumenya tinggi, dan relatif mudah untuk diotomatisasi melalui bot atau skrip. Sejumlah artikel di portal teknologi

Indonesia mencatat bahwa spam komentar judi online di YouTube semakin meresahkan, bukan hanya mengganggu kenyamanan pengguna, tetapi juga merusak integritas kanal dan membahayakan kelompok rentan seperti remaja .

Dari perspektif ilmiah, beberapa penelitian di bidang ilmu komputer secara khusus menyoroti fenomena spam komentar di YouTube. Sam'an dan Imaddudin *dalam International Journal of Electrical and Computer Engineering* menjelaskan bahwa komentar spam pada YouTube kerap digunakan untuk menyebarkan *phishing*, *malware*, dan iklan agresif, sehingga dibutuhkan model *deep learning* hibrida yang mampu mendeteksi pola spam dengan akurasi tinggi dan dapat digunakan dalam skenario moderasi *near real-time* [15].

Secara lebih khusus, Airlangga melakukan studi komparatif berbagai model *machine learning* untuk deteksi spam komentar YouTube dan menunjukkan bahwa metode berbasis fitur perilaku dan classical models efektif untuk mengenali pola spam umum, tetapi masih memiliki keterbatasan ketika berhadapan dengan spam yang lebih "rapi" dan tersamar secara semantik, misalnya promosi judi online yang menggunakan variasi kata atau simbol [8].

Penelitian lain dari UPI mengimplementasikan algoritma *Naive Bayes* untuk filtrasi spam komentar judi online di YouTube. Studi tersebut menjelaskan tahapan pengambilan data komentar melalui YouTube API, praproses teks (*normalisasi, tokenization, Stopword Removal*), hingga pengujian model *Naive Bayes* yang mampu membedakan komentar judi dan non-judi dengan tingkat akurasi tertentu. Hal ini memperkuat bukti bahwa promosi judi online melalui komentar YouTube bukan hanya fenomena sosial, tetapi juga menjadi objek kajian teknis yang serius di ranah deteksi spam [23].

Di sisi lain, Smith, Reiter, dan Peters menunjukkan bahwa model Transformer/LLM dapat digunakan untuk mendeteksi tanda-tanda perilaku terkait judi dari teks daring, walaupun konteks datanya berupa forum online berbahasa Jerman [9]. Temuan ini mengindikasikan bahwa representasi kontekstual yang kaya sangat relevan untuk mengenali pola ajakan judi, termasuk ketika pesan tersebut muncul dalam bentuk komentar pendek seperti

di YouTube.

4) Spam Komentar, *Obfuscation*, dan Tantangan Moderasi

Secara umum, spam di media sosial dapat dipahami sebagai pesan tidak diinginkan yang dikirimkan secara massal dengan tujuan tertentu (misalnya promosi, penipuan, atau penyebaran malware), sering kali tanpa memperhatikan relevansi terhadap konten utama. Taha dkk. dan Alshattnawi dkk. dalam survei dan studi deteksi spam di media sosial menekankan bahwa keterbukaan platform seperti YouTube dan Facebook membuatnya rentan terhadap spam yang memanfaatkan celah sistem dan perilaku pengguna [6] [7].

Pada konteks promosi judi online, spam komentar sering disertai teknik *obfuscation* untuk menghindari filter otomatis. Teknik ini meliputi penggunaan *leetspeak* (misalnya menulis "g4c0r" untuk "gacor"), pemisahan huruf ("s l o t" untuk "slot"), penggantian karakter dengan simbol, hingga pemotongan atau penyamaran URL sehingga tidak langsung terdeteksi sebagai tautan berbahaya. Observasi tersebut juga muncul pada rumusan masalah dan tinjauan pustaka skripsi ini yang mencatat bahwa *obfuscation* menyebabkan aturan berbasis pola sederhana (*rule-based*) sering gagal menangkap makna sebenarnya komentar.

Penelitian-penelitian mutakhir menunjukkan bahwa model *deep learning* dan Transformer (seperti BERT) lebih unggul dibandingkan pendekatan tradisional ketika konteks bahasa bersifat kompleks dan penuh penyamaran. Studi *deep learning* untuk komentar YouTube melaporkan bahwa model berbasis urutan seperti LSTM dan BiLSTM mampu menangkap dependensi konteks dan pola lokal dalam teks spam, sedangkan arsitektur hibrida yang menggabungkan BERT dengan jaringan berurutan dapat meningkatkan akurasi klasifikasi pada teks yang kaya konteks [24].

Dalam perspektif landasan teori, kombinasi karakteristik teknis YouTube, sifat terbuka kolom komentar, definisi yuridis mengenai judi online, serta sifat spam komentar yang menggunakan *obfuscation* membentuk kerangka konseptual mengapa komentar promosi judi online di YouTube menjadi masalah yang mendesak. Fenomena tersebut bukan hanya gangguan ringan,

tetapi bertentangan dengan kebijakan platform, melanggar hukum nasional, dan berpotensi merugikan pengguna terutama kelompok rentan sehingga memerlukan pendekatan moderasi proaktif berbasis *Natural Language Processing* dan *machine learning* yang kontekstual.

b. Pemrosesan Bahasa Alami (*Natural Language Processing* - NLP) dan Klasifikasi Teks

Pemrosesan Bahasa Alami (*Natural Language Processing* - NLP) adalah cabang ilmu komputer dan kecerdasan buatan yang berfokus pada bagaimana komputer dapat memahami, memproses, dan menghasilkan bahasa manusia. Dalam konteks penelitian ini, NLP digunakan untuk mengolah teks komentar YouTube sehingga dapat diklasifikasikan apakah komentar tersebut mengandung promosi judi online atau tidak. Taha dkk. merangkum bahwa berbagai tugas NLP modern seperti klasifikasi teks, analisis sentimen, dan deteksi spam pada dasarnya bertumpu pada proses transformasi teks mentah menjadi representasi numerik yang dapat dipelajari oleh algoritma *machine learning* [6].

Secara umum, rangkaian proses dalam banyak sistem NLP dapat digambarkan sebagai berikut: (1) pengumpulan data teks mentah; (2) praproses dan normalisasi; (3) pembentukan atau ekstraksi fitur; (4) pelatihan model klasifikasi; dan (5) evaluasi kinerja dengan metrik tertentu. Alur ini juga diadopsi dalam penelitian ini untuk mengolah komentar YouTube sebelum dimasukkan ke model IndoBERTweet .

1) Konsep Dasar Pemrosesan Bahasa Alami

Teks komentar di YouTube memiliki karakteristik yang berbeda dari teks formal, misalnya: pendek, penuh singkatan, emotikon, campuran bahasa, dan kadang mengandung penyamaran (*obfuscation*) seperti “g4c0r” atau “s l o t”. Pada data seperti ini, pendekatan NLP perlu dirancang dengan mempertimbangkan bahasa informal dan variasi penulisan.

Dari sisi tugas, penelitian ini berfokus pada klasifikasi teks biner, yaitu memetakan setiap komentar ke dalam dua kelas:

- komentar yang mengandung promosi judi online, dan
- komentar yang tidak mengandung promosi judi online.

Taha dkk. mengelompokkan tugas klasifikasi teks sebagai bagian dari supervised learning, di mana model dilatih menggunakan pasangan (teks, label) agar mampu mengenali pola yang membedakan satu kelas dengan kelas lainnya [6]. Struktur tugas inilah yang digunakan dalam skripsi ini: komentar diberi label "judi" atau "bukan judi", kemudian digunakan untuk melatih model deteksi.

2) Tahapan Praproses Teks dalam NLP

Praproses teks bertujuan membersihkan dan menormalkan komentar mentah agar lebih mudah dipelajari model. Tanpa praproses yang memadai, model akan "dibanjiri" variasi kata yang sebenarnya mirip, sehingga kinerja klasifikasi menurun [6] [14]. Tahapan praproses yang relevan untuk penelitian ini antara lain:

- Tokenisasi

Tokenisasi adalah proses memecah teks menjadi unit-unit kecil (token), biasanya berupa kata atau sub-kata. Pada komentar YouTube, proses ini penting karena model bekerja pada urutan token, bukan pada kalimat utuh dalam bentuk string.

- Normalisasi dan *case folding*

Normalisasi mencakup penyamaan huruf besar–kecil (menjadikan teks ke huruf kecil), penghilangan karakter yang tidak perlu, serta perapihan penulisan yang tidak baku. Pada komentar YouTube, normalisasi juga membantu menyederhanakan variasi penulisan yang kreatif.

- *Stopword Removal*

Stopword adalah kata-kata yang sangat sering muncul tetapi tidak terlalu membantu untuk membedakan kelas, seperti "dan", "atau", "yang", dan sejenisnya. Menghapus sebagian *Stopword* dapat mengurangi dimensi fitur dan membuat model lebih fokus pada kata-kata kunci yang penting.

- *Stemming* atau *lemmatization*

Stemming mengubah kata ke bentuk dasarnya dengan memotong imbuhan (contoh: “bermain”, “memainkan” → “main”). Pada bahasa Indonesia, berbagai algoritma *Stemming* telah dikembangkan dan banyak dimanfaatkan dalam penelitian klasifikasi teks [14].

- Normalisasi anti-*obfuscation*

Khusus untuk komentar promosi judi online, dibutuhkan langkah tambahan untuk menangani *obfuscation*, misalnya: mengganti angka dengan huruf yang setara (“4” → “a”, “0” → “o”), menggabungkan huruf yang dipisah spasi (“s l o t” → “slot”), serta melakukan masking URL agar tautan yang disamarkan tetap dikenali. Tahapan ini penting karena spammer sering memanfaatkan variasi penulisan untuk mengelabui filter berbasis kata kunci sederhana.

Tahapan-tahapan praproses di atas akan diterapkan sebelum komentar masuk ke tokenizer model IndoBERTweet, sehingga model mendapatkan masukan yang sudah dibersihkan tetapi makna pentingnya tetap terjaga.

3) Representasi Teks

Setelah teks dibersihkan, komentar perlu diubah menjadi bentuk numerik (vektor) agar dapat diproses oleh algoritma *machine learning*. Dalam literatur NLP, terdapat beberapa pendekatan representasi teks yang populer:

- *Bag-of-Words* dan TF-IDF

Pendekatan lama seperti *Bag-of-Words* (BoW) dan *Term Frequency-Inverse Document Frequency* (TF-IDF) merepresentasikan teks sebagai vektor berdasarkan frekuensi kemunculan kata. Zulqarnain dkk. mencatat bahwa meskipun sederhana, TF-IDF masih kompetitif sebagai fitur untuk model klasik seperti *Naive Bayes* atau SVM [14].

- *Word embeddings*

Word embeddings memetakan kata ke ruang vektor berdimensi rendah sehingga kata yang mirip makna diletakkan berdekatan. Representasi ini lebih kaya secara semantik dibanding BoW/TF-IDF dan banyak digunakan pada model CNN/RNN untuk teks.

- Representasi kontekstual

Representasi kontekstual menghasilkan vektor yang bergantung pada konteks kalimat, sehingga kata yang sama bisa memiliki arti vektor berbeda jika muncul dalam kalimat berbeda. Taha dkk. menyoroti bahwa representasi kontekstual berbasis Transformer menjadi tren utama dalam penelitian klasifikasi teks modern [6]. Dalam konteks bahasa Indonesia, Koto dkk. merilis IndoBERT sebagai model pra-latih yang secara khusus dilatih pada korpus bahasa Indonesia dan terbukti memberi performa baik pada berbagai tugas NLP Indonesia [17].

Penelitian ini menggunakan BERT/IndoBERTweet sebagai sumber representasi kontekstual. BoW dan TF-IDF tetap dijadikan landasan teoritis untuk menjelaskan evolusi pendekatan representasi teks, tetapi fokus implementasi ada pada pendekatan kontekstual.

4) Klasifikasi Teks pada Komentar Media Sosial

Klasifikasi teks adalah proses memetakan setiap teks ke satu atau beberapa label. Dalam penelitian ini, klasifikasi dilakukan secara biner, yaitu membedakan komentar yang mengandung promosi judi online dan komentar yang tidak mengandung promosi judi online.

Dalam tinjauan Taha dkk., pendekatan klasifikasi teks dibagi menjadi dua kelompok besar:

(1) model klasik berbasis fitur (seperti *Naive Bayes*, SVM, *Logistic Regression*) dan

(2) model *deep learning* seperti CNN, RNN, hingga Transformer [6]. Zulqarnain dkk. mengulas bahwa CNN dan RNN cukup efektif untuk menangkap pola lokal dan urutan kata, namun memiliki keterbatasan saat konteks kalimat menjadi lebih panjang dan kompleks [14].

Untuk domain komentar YouTube, penelitian di Indonesia menunjukkan bahwa:

- Airlangga membandingkan berbagai model *machine learning* lanjutan untuk deteksi spam komentar YouTube, dan menemukan bahwa kombinasi fitur perilaku dan model klasik ampuh untuk spam umum, namun masih

lemah dalam menghadapi spam yang tersamar secara semantik [8].

- Jauhari dkk. menerapkan *Naive Bayes* untuk filtrasi spam komentar judi online di YouTube dan menunjukkan bahwa pendekatan content-based sederhana pun dapat memisahkan komentar judi dan non-judi, meskipun respons terhadap *obfuscation* masih terbatas [23].

Dari berbagai temuan tersebut, dapat disimpulkan bahwa klasifikasi teks adalah pendekatan yang wajar dan sudah banyak digunakan untuk deteksi spam komentar YouTube. Namun, untuk kasus promosi judi online yang menggunakan bahasa campuran dan teknik *obfuscation*, dibutuhkan model yang lebih kontekstual seperti BERT, sehingga nuansa makna dalam komentar pendek tetap dapat ditangkap dengan baik

5) Metrik Evaluasi Kinerja Model Klasifikasi

Agar kinerja model klasifikasi dapat dinilai secara objektif, diperlukan metrik evaluasi. Dalam tugas deteksi komentar judi online, tidak cukup hanya melihat akurasi; yang lebih penting adalah seberapa baik model mengenali komentar berbahaya tanpa terlalu banyak menandai komentar yang sebenarnya sah.

Beberapa metrik yang digunakan dalam penelitian ini adalah:

- *Accuracy*

Mengukur proporsi prediksi yang benar terhadap seluruh prediksi. Namun, pada data yang tidak seimbang (misalnya jumlah komentar judi jauh lebih sedikit dari komentar normal), akurasi saja seringkali menyesatkan.

- *Precision*

Mengukur seberapa banyak prediksi positif yang benar-benar positif. Dalam konteks ini, *Precision* yang tinggi berarti sebagian besar komentar yang diprediksi sebagai promosi judi memang benar komentar judi. Ini penting untuk mengurangi komentar normal yang keliru ditandai sebagai spam.

- *Recall*

Mengukur seberapa besar bagian komentar judi yang berhasil ditangkap oleh model. *Recall* yang tinggi membantu mengurangi komentar judi yang

"lolos" dari sistem moderasi.

- F1-score

Merupakan rata-rata harmonik antara *Precision* dan *Recall*, sehingga memberikan gambaran keseimbangan keduanya. Pada deteksi komentar judi, F1-score sering dijadikan indikator utama keberhasilan model .

- *Precision–Recall Curve* dan PR-AUC

Pada kasus ketidakseimbangan kelas, kurva *Precision–Recall* dan area di bawahnya (PR-AUC) memberikan gambaran bagaimana trade-off antara *Precision* dan *Recall* pada berbagai nilai ambang. Metrik ini sangat relevan ketika kelas positif (komentar judi) jauh lebih sedikit tetapi sangat penting untuk dideteksi dengan benar.

Metrik-metrik di atas digunakan untuk menilai apakah model BERT yang dibangun sudah layak dipakai dalam skenario moderasi proaktif. Nilai *Precision* dan *Recall* pada kelas "judi" akan menjadi perhatian utama, sementara F1-score dan PR-AUC memberikan gambaran menyeluruh tentang keseimbangan kinerja model.

c. Arsitektur Transformer dan Model BERT

Secara garis besar, penelitian ini memanfaatkan keluarga model Transformer, khususnya BERT (*Bidirectional Encoder Representations from Transformers*), sebagai inti pemodelan teks komentar YouTube yang mengandung atau tidak mengandung promosi judi. Bagian ini menguraikan konsep dasar arsitektur Transformer, pengertian BERT, proses *pre-training* dan *fine-tuning*, varian BERT bahasa Indonesia (IndoBERT/IndoBERTweet), serta alasan mengapa BERT relevan untuk menangani komentar yang beragam dan sering diobfusikasi.

1) Konsep Dasar Arsitektur Transformer

Secara konseptual, Transformer adalah arsitektur jaringan saraf untuk pemrosesan urutan (*sequence*) yang menggantikan peran RNN atau CNN dengan mekanisme attention sebagai komponen utama. Vaswani dkk. memperkenalkan Transformer sebagai arsitektur encoder–decoder berbasis

attention murni untuk tugas penerjemahan mesin dan menunjukkan bahwa model ini lebih mudah diparalelkan serta lebih efisien dibanding arsitektur berulang klasik [25].

Dalam konteks penelitian ini, bagian yang paling relevan adalah encoder Transformer, karena BERT dibangun sebagai tumpukan encoder berlapis-lapis. Encoder Transformer secara garis besar terdiri dari:

- Lapisan *self-attention* multi-kepala (*multi-head self-attention*) yang memungkinkan model "memperhatikan" setiap token relatif terhadap token lain dalam satu kalimat/urutan.
- *Feed-forward network* posisi-per-posisi yang bekerja pada representasi tiap token setelah proses attention.
- Penjumlahan residual dan normalisasi layer (*residual connection* + layer *normalization*) untuk menjaga stabilitas gradien dan membantu pelatihan model yang dalam.
- *Positional encoding* untuk menyisipkan informasi urutan posisi token, karena *self-attention* tidak memiliki konsep urutan intrinsik.

Mekanisme *self-attention* menghitung bobot perhatian antar token dalam satu urutan sehingga model dapat mengidentifikasi kata-kata yang paling relevan untuk memahami makna suatu token. Misalnya, dalam komentar yang mengandung frasa tersamar seperti "s l0 t gac0r malam ini", model dapat belajar bahwa token-token "slot" dan "gacor" saling terkait meskipun terdapat variasi penulisan. Kemampuan menangkap dependensi jarak jauh dan pola relasi antarkata inilah yang membuat Transformer unggul dalam tugas-tugas pemahaman bahasa yang kompleks [25].

Survei modern tentang klasifikasi teks juga menunjukkan bahwa model berbasis Transformer (misalnya BERT, RoBERTa, dan turunannya) cenderung mengungguli model klasik ketika konteks bahasa kompleks, panjang, dan kaya nuansa semantik [17].

2) Pengertian BERT (Bidirectional Encoder Representations from Transformers)

BERT adalah model representasi bahasa yang dibangun di atas encoder Transformer dan dilatih untuk menghasilkan representasi kontekstual dua arah dari teks. Devlin dkk. mendefinisikan BERT sebagai model yang "membaca" teks secara simultan dari kiri-ke-kanan dan kanan-ke-kiri, sehingga setiap token direpresentasikan dengan mempertimbangkan konteks penuh di kedua arah [18].

Secara umum, karakteristik utama BERT adalah:

1. Berbasis encoder Transformer

   BERT terdiri atas beberapa lapisan encoder Transformer yang sama struktur dasarnya dengan yang dijelaskan pada subbagian sebelumnya (*self-attention*, *feed-forward*, *residual connection*, *positional encoding*).

2. *Bidirectional contextual representation*

   Berbeda dengan model berbasis bahasa satu arah (unidirectional language model), BERT mempelajari representasi token dengan mempertimbangkan kata sebelum dan sesudah token tersebut sekaligus. Hal ini penting untuk mendeteksi makna yang bergantung pada konteks, misalnya membedakan "slot" sebagai istilah game judi dengan "slot" sebagai "waktu kosong" bergantung pada kalimat sekitarnya.

3. Pre-trained lalu di-*fine-tune*

   BERT dilatih secara umum (*pre-training*) pada korpus teks besar untuk mempelajari pola bahasa, lalu diadaptasi (*fine-tuning*) dengan menambahkan lapisan keluaran sederhana (misalnya classifier) untuk tugas spesifik seperti klasifikasi komentar judi vs non-judi [18].

Dalam proposal ini, BERT diposisikan sebagai *backbone* pemodelan teks yang memberikan vektor representasi komentar YouTube, yang kemudian digunakan oleh lapisan klasifikasi biner untuk menentukan apakah komentar tersebut memuat promosi judi.

3) Proses *Pre-training* dan *Fine-tuning* BERT untuk Klasifikasi Teks

BERT dilatih dalam dua tahap besar: *pre-training* dan *fine-tuning*. Tahap *pre-training* dilakukan sekali oleh pengembang model (misalnya tim BERT atau tim IndoBERT), sementara *fine-tuning* dilakukan oleh peneliti pada dataset tugas spesifik (di sini: komentar promosi judi di YouTube) [18].

1. *Pre-training*

   Pada tahap ini, BERT dilatih pada korpus teks besar menggunakan dua tugas utama:

   - Masked Language Modeling (MLM)

     Sejumlah token dalam kalimat disensor (diganti dengan token khusus MASK atau variasi lain), dan model diminta memprediksi token asli yang hilang. Tugas ini memaksa BERT mempelajari hubungan semantik dan sintaksis antar kata dalam konteks dua arah.
   - *Next Sentence Prediction* (NSP)

     Pasangan kalimat A dan B diberikan, dan model diminta memprediksi apakah B benar-benar kalimat lanjutan dari A atau hanya pasangan acak. Tugas ini membantu model memahami relasi antar kalimat dan kohesi wacana.

   Hasil dari tahap ini adalah model bahasa umum (*general-purpose language model*) yang sudah memahami struktur bahasa secara luas tanpa spesifik ke satu tugas.

2. *Fine-tuning* untuk klasifikasi teks

   Setelah *pre-training*, BERT diadaptasi pada tugas spesifik dengan cara:

   - Menambahkan lapisan klasifikasi (output layer) di atas representasi token khusus [CLS] yang mewakili keseluruhan kalimat/komentar.
   - Melatih ulang (*fine-tune*) semua parameter BERT (dan lapisan klasifikasi) menggunakan dataset berlabel, misalnya komentar judi vs non-judi.
   - Menggunakan fungsi loss klasifikasi (*cross-entropy*) dan optimasi berbasis *gradient descent*.

   Dalam konteks skripsi ini, *fine-tuning* dilakukan menggunakan data

komentar YouTube berbahasa Indonesia yang sudah dilabeli 0/1 (bukan judi / promosi judi), dengan mempertimbangkan teknik seperti class weighting untuk mengatasi ketidakseimbangan kelas, serta early stopping dan threshold calibration untuk mengoptimalkan metrik F1 dan *Precision* kelas positif (komentar judi) [6] [14].

Pendekatan "*pre-train once, fine-tune many*" ini membuat peneliti tidak perlu melatih model besar dari nol, sehingga lebih efisien secara komputasi namun tetap mendapatkan performa tinggi dalam klasifikasi teks domain tertentu.

4) Model BERT untuk Bahasa Indonesia (IndoBERT dan IndoBERTweet)

Untuk tugas berbahasa Indonesia, penggunaan BERT bahasa Inggris murni (*bert-base-uncased*) seringkali kurang optimal karena perbedaan kosakata dan struktur bahasa. Oleh karena itu, penelitian ini memanfaatkan model BERT yang secara khusus dipre-train untuk bahasa Indonesia, terutama IndoBERT dan IndoBERTweet.

1. IndoBERT

   IndoBERT adalah varian BERT yang dilatih secara monolingual pada korpus bahasa Indonesia berukuran lebih dari 200 juta kata, termasuk Wikipedia Indonesia, korpus berita (Kompas, Tempo, Liputan6), dan web corpus Indonesia [25]. Koto dkk. merilis IndoBERT bersamaan dengan benchmark IndoLEM, dan menunjukkan bahwa IndoBERT mencapai kinerja *state-of-the-art* pada berbagai tugas NLP Indonesia seperti *part-of-speech tagging*, *named entity recognition*, dan *dependency parsing* [17].

   - Dalam konteks skripsi ini, IndoBERT menjadi model dasar (*baseline* utama) untuk klasifikasi komentar judi karena:
     - Kosakatanya sudah kaya akan kata/frasa bahasa Indonesia.
     - Representasi kontekstual yang dihasilkan lebih sesuai dengan pola bahasa Indonesia dibanding model bahasa Inggris murni.
   - IndoBERT sudah tercantum di daftar pustaka sebagai referensi .

2. IndoBERTweet

IndoBERTweet merupakan model pre-trained BERT yang secara khusus dilatih pada data Twitter berbahasa Indonesia, dengan penambahan kosakata domain-spesifik media sosial. Model ini dikembangkan dengan cara memperluas IndoBERT dengan vocabulary baru yang khas Twitter (slang, singkatan, penulisan informal), dan terbukti efektif menangani teks informal dan pendek di media sosial [18].

Karakteristik IndoBERTweet sangat relevan dengan komentar YouTube, karena:

- Banyak komentar meniru gaya bahasa media sosial (singkatan, emoji, ejaan kreatif).
- Terdapat banyak *obfuscation* dan variasi penulisan (misalnya "sl0t", "s l o t", nama situs yang dipotong-potong).
- Panjang teks biasanya pendek hingga menengah, mirip dengan cuitan Twitter.

Oleh karena itu, skripsi ini memosisikan IndoBERT dan IndoBERTweet sebagai kandidat model dasar (*backbone*) untuk *fine-tuning* deteksi komentar promosi judi, dengan *bert-base-uncased* sebagai pembanding lintas-bahasa.

5) Kelebihan BERT dalam Menangani Teks Komentar yang Beragam dan Mengandung *Obfuscation*

Komentar YouTube yang memuat promosi judi online memiliki beberapa karakteristik khusus:

- Beragam gaya bahasa: formal, semi-formal, slang, campuran bahasa Indonesia–Inggris, bahkan emote dan simbol.
- Penyamaran (*obfuscation*): penggunaan *leetspeak* ("g4c0r", "j*d1"), pemisahan huruf ("s l o t"), pemotongan atau masking URL, dan istilah kode tertentu.
- Konteks pendek namun sarat maksud: satu komentar pendek bisa mengandung ajakan, nama situs, dan iming-iming bonus.

Model BERT (dan turunannya) memiliki beberapa keunggulan untuk

menangani karakteristik tersebut:

1. Representasi kontekstual dua arah

   Karena BERT melihat konteks kiri dan kanan, model dapat membedakan penggunaan kata yang sama dengan makna berbeda bergantung konteks. Misalnya, "slot" dalam konteks "slot mesin judi online" vs "slot jadwal kuliah" akan menghasilkan representasi yang berbeda, sehingga classifier tidak sekadar bergantung pada kehadiran kata permukaan saja [6] [14].

2. Tokenisasi *subword* (WordPiece/BPE)

   BERT menggunakan tokenisasi *subword*, sehingga kata-kata yang diobfusikasi seperti "sl0t", "s1ot", atau "s l o t" cenderung terpecah menjadi token *subword* yang masih menyimpan kedekatan dengan token normal "slot". Hal ini membuat model lebih tangguh dibanding pendekatan berbasis kata murni, yang mungkin gagal mengenali variasi ejaan kreatif.

3. Kemampuan menangkap pola sintaksis dan semantik kompleks

   Studi terkait model Transformer untuk spam dan klasifikasi teks menunjukkan bahwa representasi kontekstual mampu meningkatkan performa deteksi pada teks media sosial yang penuh nuansa, dibandingkan pendekatan berbasis fitur permukaan saja (n-gram, *Bag-of-Words*) [7] [16].

4. Fleksibilitas integrasi dengan pipeline moderasi

   BERT dapat diintegrasikan dalam pipeline moderasi otomatis dengan cara:

   - Menghasilkan skor probabilitas komentar "promosi judi",
   - Mengaplikasikan threshold yang dikalibrasi (misalnya untuk menjamin *Precision* tinggi pada kelas positif),
   - Menyisipkan mekanisme *human-in-the-loop* untuk kasus borderline, sehingga mengurangi risiko false positive terhadap komentar sah [8] [23].

Dengan kombinasi *preprocessing* anti-*obfuscation*, model BERT berbasis bahasa Indonesia (IndoBERT/IndoBERTweet), dan strategi *fine-tuning* yang tepat, sistem yang dibangun diharapkan mampu menangkap pola promosi judi terselubung di komentar YouTube secara lebih akurat dibanding pendekatan *rule-based* atau model klasik.

d. YouTube Data API v3 untuk Moderasi Komentar

1) Konsep API dan Endpoint untuk Moderasi Komentar (ambil komentar & ubah status moderasi)

Application Programming Interface (API) adalah antarmuka yang memungkinkan aplikasi saling berkomunikasi untuk mengakses fitur/layanan tertentu secara terstandar. Dalam konteks integrasi sistem, pola yang umum adalah arsitektur layanan berbasis HTTP/REST yang memfasilitasi pertukaran data antara *client* dan *server* melalui *endpoint-endpoint* yang disediakan penyedia layanan [26]. Pada penelitian ini, integrasi dilakukan melalui YouTube Data API v3 sebagai API resmi yang memungkinkan aplikasi menambahkan fungsionalitas YouTube, termasuk pengelolaan komentar dan moderasinya [10].

a) *Resource* dan *endpoint* untuk pengambilan komentar

YouTube Data API memodelkan data sebagai *resource*. Untuk komentar, *resource* penting adalah:

1. commentThreads

   Resource commentThread merepresentasikan rangkaian komentar pada sebuah video (komentar tingkat atas beserta balasannya jika ada). Namun, *Resource* commentThread tidak menjamin memuat semua balasan, sehingga bila membutuhkan seluruh balasan untuk satu komentar, perlu menggunakan metode comments.list [10].

2. comments

   Resource comment merepresentasikan komentar individual (komentar tingkat atas maupun balasan). Secara praktik, integrasi pengambilan data komentar sering diawali dari commentThreads.list (untuk daftar *thread*), lalu dilanjutkan comments.list bila perlu mengambil seluruh balasan atau detail komentar tertentu [10].

Dalam pedoman implementasi komentar, Google menjelaskan contoh alur moderasi: untuk mengambil komentar yang “ditahan untuk ditinjau”, sistem dapat memanggil commentThreads.list dan mengisi parameter moderationStatus=heldForReview sehingga respons API dapat dipakai untuk

menyusun daftar antrean moderasi .

b) *Endpoint* untuk mengubah status moderasi komentar

Aksi moderasi inti dilakukan dengan *endpoint*:

- comments.setModerationStatus

  Metode ini digunakan untuk mengubah status moderasi satu atau beberapa komentar. Dokumentasi resmi menyatakan request harus diotorisasi oleh pemilik channel atau video yang terkait komentar tersebut Parameter kunci yang umum dipakai:
- id: daftar ID komentar yang statusnya akan diubah
- moderationStatus: status target, dengan nilai seperti heldForReview, published, atau rejected. Selain itu ada opsi banAuthor (boolean) untuk menolak otomatis komentar berikutnya dari penulis komentar (berguna saat spammer berulang), dengan ketentuan tertentu

2) OAuth 2.0 untuk Otorisasi Kanal (Channel Authorization)

Pada integrasi YouTube Data API, ada pemisahan peran antara:

- aplikasi/sistem moderasi (dashboard + backend) sebagai *client*,
- pemilik kanal sebagai *resource owner*,
- Google/YouTube sebagai penyedia layanan yang mengeluarkan token dan melindungi *resource*.

Secara standar, OAuth 2.0 adalah *authorization framework* yang memungkinkan aplikasi pihak ketiga memperoleh akses terbatas ke layanan berbasis HTTP, baik atas nama pemilik *Resource* (melalui persetujuan) maupun untuk akses tertentu, tanpa membagikan kredensial [12].

a) Mengapa OAuth 2.0 diperlukan pada moderasi komentar

Moderasi komentar termasuk operasi yang berdampak langsung pada kanal (misalnya memublikasikan/menolak komentar), sehingga YouTube mensyaratkan request yang melakukan aksi tersebut harus terotorisasi. Dokumentasi comments.setModerationStatus menegaskan bahwa request perlu diotorisasi oleh pemilik channel/video terkait [10].

Dari perspektif keamanan integrasi, OAuth 2.0 memungkinkan akses

diberikan melalui mekanisme token sehingga *client* tidak perlu menyimpan atau meminta username/password pemilik kanal. Literatur SSO menyebut OAuth memungkinkan pengguna memberi otorisasi kepada *client* untuk mengakses data pada server dengan token, tanpa membagikan kredensial login [26].

b) Peran token dan implikasinya pada desain sistem

Dalam implementasi OAuth 2.0, akses ke API umumnya memakai access token (berumur terbatas), dan pada skenario tertentu memakai refresh token untuk memperoleh access token baru saat yang lama kedaluwarsa. Pada studi implementasi OAuth 2.0 (kasus SSO), dijelaskan penggunaan token (request token/access token/refresh token) sebagai bagian dari proses otorisasi dan autentikasi akses API, serta untuk meningkatkan kenyamanan dan efisiensi [26] Implikasi ke rancangan moderasi komentar:

1. Penyimpanan token yang aman

   Access token/refresh token tergolong rahasia aplikasi. Desain backend perlu menempatkan token pada penyimpanan aman (*secret manager*/*encrypted storage*) dan membatasi aksesnya hanya untuk komponen yang membutuhkan.

2. Manajemen masa berlaku token

   Karena access token dapat kedaluwarsa, sistem perlu menangani *refresh flow* (bila refresh token tersedia) atau memicu proses login ulang pemilik kanal sesuai kebutuhan.

3. Scope akses

   Dokumentasi comments.setModerationStatus mensyaratkan otorisasi dengan scope tertentu (youtube.force-ssl) yang merepresentasikan ruang lingkup izin. Ini penting untuk prinsip *least privilege* [10]

3) Kuota/Rate Limit dan Dampaknya ke Desain Sistem Moderasi

a) Konsep kuota pada YouTube Data API

YouTube Data API menerapkan sistem kuota agar layanan digunakan sesuai tujuan dan tidak menurunkan kualitas layanan untuk pengguna lain. Dokumentasi overview menegaskan setiap request API termasuk request yang

tidak valid tetap menimbulkan biaya kuota minimal. Secara default, proyek yang mengaktifkan YouTube Data API memperoleh alokasi 10.000 unit per hari [10].

Selain kuota harian, desain integrasi juga perlu memperhatikan praktik pembatasan laju (*rate limiting*) di sisi layanan API (misalnya lonjakan request dalam waktu singkat dapat memicu error 403/429 pada beberapa layanan Google). Walau detail *rate limit* dapat bervariasi, prinsip desain yang aman adalah menghindari pola "*spam request*" dan memakai penjadwalan/paginasi yang efisien.

b) Biaya kuota untuk *endpoint* komentar dan konsekuensi arsitektural

Pada tabel "kalkulator kuota", operasi komentar memiliki biaya berbeda. Untuk konteks moderasi komentar:

- commentThreads.list berbiaya rendah (1 unit) sehingga cocok untuk polling/penarikan daftar thread komentar [10].
- comments.setModerationStatus berbiaya 50 unit per panggilan. [10]

Konsekuensi desain:

1. Optimasi jumlah panggilan moderasi (write)
    - Karena *write call* mahal (50 unit), sistem perlu meminimalkan pemanggilan berulang. Contohnya: hanya mengubah status ketika prediksi model melewati ambang tertentu, atau mengelompokkan beberapa ID komentar dalam satu request (jika relevan dan didukung parameter *endpoint*) [10].
2. Strategi antrean moderasi (*moderation queue*)
    - Pedoman implementasi komentar menyarankan alur dua langkah: ambil komentar *heldForReview*, lalu putuskan publikasi/penolakan. Ini selaras dengan desain *queue* yang memisahkan "pengambilan kandidat" (murah) vs "eksekusi tindakan" (mahal) .
3. Pengendalian polling dan paginasi
    - Dokumentasi kuota menjelaskan bahwa bila metode list menghasilkan banyak halaman, setiap halaman tambahan menambah biaya kuota. Maka, desain perlu membatasi frekuensi

polling dan menggunakan paginasi secara terukur (misalnya interval adaptif: lebih sering saat volume tinggi, lebih jarang saat sepi).

4. Partial response untuk efisiensi
   - YouTube Data API mendukung pengambilan "*partial Resource*s" melalui parameter part dan fields untuk mengurangi data tidak perlu, sehingga lebih hemat bandwidth dan efisien

c) Dampak ketika kuota tidak cukup: audit dan perpanjangan kuota

Jika kebutuhan sistem meningkat melampaui kuota default, Google menyatakan permintaan kuota tambahan mensyaratkan audit kepatuhan terhadap ketentuan layanan YouTube API, dan prosesnya dilakukan melalui formulir audit/perpanjangan kuota resmi.

Implikasinya: sejak awal, rancangan sistem moderasi perlu mempertimbangkan kepatuhan kebijakan (misalnya tujuan penggunaan, penyimpanan data, dan perilaku aplikasi) agar tidak menyulitkan saat mengajukan peningkatan kuota.

e. Teknologi Implementasi Sistem Moderasi

1) Python

Python adalah bahasa pemrograman tingkat tinggi yang bersifat *interpreted* (dijalankan melalui interpreter) dan mendukung berbagai paradigma pemrograman. Dokumentasi resmi Python menjelaskan Python sebagai bahasa yang *interpreted*, interaktif, dan berorientasi objek, dengan dukungan modul, *exception*, *dynamic typing*, serta tipe data tingkat tinggi [27]. Selain itu, Python banyak dipakai untuk mengintegrasikan komponen sistem karena dapat berperan sebagai *scripting/glue language* untuk "menjembatani" komponen yang berbeda dalam satu workflow aplikasi [27].

Dalam konteks NLP dan *machine learning*, Python dipilih karena ekosistem pustaka yang matang untuk pemrosesan data, pelatihan model, evaluasi, hingga deployment. Pada halaman resmi Python.org juga dicontohkan area penggunaan Python yang mencakup komputasi ilmiah dan numerik (misalnya SciPy, Pandas) serta pengembangan web (misalnya Flask) . Hal ini relevan

untuk sistem moderasi komentar yang membutuhkan pipeline lengkap: ambil data komentar → olah data → klasifikasi → panggil API moderasi [27]. Python 3.x ditetapkan sebagai bahasa utama implementasi sehingga seluruh pipeline pemodelan dan integrasi sistem disatukan dalam satu ekosistem pengembangan.

Peran Python pada sistem moderasi komentar (sesuai rancangan proposal) dapat dipetakan menjadi:

1. Pemrosesan data & *text preprocessing*: membaca data komentar (CSV/JSON), pembersihan, normalisasi anti-*obfuscation* sebelum tokenisasi (misalnya pemetaan *leetspeak*, penggabungan huruf terpisah).
2. Orkestrasi pemodelan NLP berbasis Transformer: memanggil tokenizer dan model (IndoBERT/IndoBERTweet) melalui pustaka Transformers, menjalankan *fine-tuning*, lalu inference untuk memberi skor "promosi judi".
3. Integrasi layanan: Python memudahkan pembuatan service/API internal (misalnya *endpoint* klasifikasi) dan integrasi dengan API eksternal seperti YouTube Data API v3 untuk aksi moderasi (menahan /menolak/mempublikasikan komentar).

2) HuggingFace Transformers

Hugging Face Transformers adalah pustaka yang menyediakan model-model *pretrained* mutakhir untuk *inference* maupun *training* (pelatihan/*fine-tuning*). Dokumentasi resminya menegaskan Transformers menyediakan fitur yang dibutuhkan untuk *inference* atau *training* dengan model pretrained *state-of-the-art* [28]. Pada dokumentasi Hub juga dijelaskan bahwa Transformers dipelihara oleh Hugging Face dan komunitas, mendukung *PyTorch*/TensorFlow/JAX, serta menyediakan ribuan model pretrained untuk berbagai tugas (teks, visi, audio) [29].

Dalam pipeline moderasi komentar, Transformers dipakai sebagai "jembatan" praktis untuk memanfaatkan BERT/IndoBERT/IndoBERTweet tanpa membangun arsitektur dari nol. Secara konseptual, komponen intinya dapat dijelaskan sebagai berikut:

1. Tokenizer (pra-pemrosesan input model)

Tokenizer bertugas menyiapkan masukan untuk model. Dokumentasi resmi menyebut tokenizer menyiapkan input dan tersedia untuk semua model; banyak tokenizer tersedia dalam versi "Python" dan versi "Fast" berbasis Rust (lebih cepat dan mendukung pemetaan posisi karakter-kata ke token) [29]. Bagi moderasi komentar, tokenizer penting karena komentar mentah harus diubah menjadi representasi token (misalnya *input_ids*, *attention_mask*) agar bisa diproses BERT. Tokenisasi mengikuti model dasar (IndoBERT/IndoBERTweet) dan didahului normalisasi anti-*obfuscation* agar variasi ejaan dapat ditangani lebih robust.

2. Model (Transformer/BERT sebagai *backbone*) Transformers menyediakan *AutoModel*/*AutoModelForSequenceClassification* (umumnya dipakai pada klasifikasi teks) sehingga model dapat di-*load* sesuai *checkpoint* pretrained lalu diadaptasi untuk klasifikasi biner. Konsep "pretrained lalu *fine-tune*" ini sejalan dengan pendekatan proposal: model dasar IndoBERT/IndoBERTweet di-*fine-tune* pada dataset komentar berlabel untuk deteksi promosi judi.
3. *Fine-tuning* (adaptasi model pretrained ke tugas spesifik) Dokumentasi resmi menjelaskan Transformers menyediakan *Trainer API* untuk mendukung proses *fine-tuning* dan fitur pelatihan yang cukup lengkap untuk berbagai model di Hub. Konsep *fine-tuning* sendiri (melatih ulang model pretrained pada dataset spesifik tugas) juga dijelaskan sebagai cara memanfaatkan model SOTA tanpa melatih dari nol, sehingga lebih efisien secara komputasi.
4. Inference (prediksi cepat untuk penggunaan operasional) Transformers menyediakan *pipeline* sebagai cara sederhana dan teroptimasi untuk melakukan inference untuk banyak tugas ML. Dokumentasi "Pipelines" menekankan pipeline mengabstraksi kompleksitas kode dan memberi API sederhana untuk berbagai tugas termasuk klasifikasi/sentimen/ekstraksi fitur [29]. Pada sistem moderasi, inference dipakai untuk memberi skor/probabilitas "promosi judi", lalu keputusan moderasi dapat ditentukan berdasarkan ambang (threshold) dan/atau skema

human-in-the-loop sesuai rancangan penelitian.

3) *PyTorch*/TensorFlow (konsep training/inference)

Pada penelitian ini, pelatihan model dilakukan menggunakan *PyTorch* atau TensorFlow.

Keduanya adalah *deep learning framework* yang menyediakan representasi tensor, komputasi numerik, serta mekanisme pelatihan model modern (optimisasi berbasis gradien).

a) Konsep "training" (pelatihan)

Training pada model *deep learning* umumnya melibatkan: (1) *forward pass* untuk menghasilkan prediksi, (2) menghitung *loss*, lalu (3) *backpropagation* untuk memperbarui bobot berdasarkan gradien. Pada *PyTorch*, mekanisme gradien ditangani oleh torch.autograd. Tutorial resmi *PyTorch* menjelaskan bahwa *PyTorch* memiliki mesin diferensiasi bawaan (torch.autograd) yang menghitung gradien secara otomatis untuk *computational graph [30]*. Catatan *PyTorch* juga menerangkan autograd merekam operasi yang membentuk data sebagai graf terarah dan gradien dihitung melalui *chain rule* (aturan rantai) [30].

Pada TensorFlow, pelatihan banyak dilakukan melalui Keras (API tingkat tinggi). Dokumentasi tf.keras.Model menjelaskan alur umum: compile(), fit() untuk melatih, dan predict() untuk prediksi [31]. Ini sesuai kebutuhan penelitian karena *fine-tuning* BERT dapat dilakukan baik pada backend *PyTorch* maupun TensorFlow melalui ekosistem Transformers.

b) Konsep "inference" (prediksi/penggunaan)

Inference adalah penggunaan model terlatih untuk menghasilkan prediksi pada data baru, umumnya tanpa menghitung gradien. Pada *PyTorch*, dokumentasi torch.no_grad() menyebut menonaktifkan perhitungan gradien berguna untuk inference karena mengurangi konsumsi memori dan mempercepat eksekusi [30]. Pada TensorFlow/Keras, inference umumnya dilakukan dengan predict() sebagaimana disebut pada dokumentasi Model Keras [31].

c) Implikasi ke desain sistem moderasi

Karena sistem moderasi mengarah ke penggunaan operasional (mendeteksi komentar baru lalu memoderasi), pipeline biasanya dipisah menjadi:

- Mode pelatihan (offline/periodik): *fine-tuning*, validasi, kalibrasi threshold.
- Mode inference (online/real-time): tokenisasi cepat + prediksi + keputusan moderasi + panggilan API YouTube. Pemisahan ini penting agar beban komputasi training tidak mengganggu respon sistem saat memproses komentar masuk.

4) Pandas/NumPy (olah data)

Pada proposal, pandas dan NumPy ditetapkan sebagai pustaka untuk olah data komentar dan dataset latih-uji.

Keduanya lazim dipakai berpasangan: NumPy menangani komputasi array numerik, sementara pandas memudahkan manipulasi data tabular.

a) pandas

Dokumentasi resmi pandas menyebut pandas adalah pustaka *open source* berlisensi BSD yang menyediakan struktur data berkinerja tinggi dan mudah digunakan untuk analisis data di Python [32]. Struktur data utama pandas adalah DataFrame dijelaskan sebagai struktur data 2-dimensi berbentuk tabel, dapat berubah ukuran, dapat heterogen, dengan label baris dan kolom; DataFrame adalah struktur data utama pandas [32].

Dalam sistem moderasi, DataFrame dipakai untuk:

- Menyimpan komentar mentah + metadata (commentId, videoId, timestamp, teks komentar).
- Melakukan pembersihan (hapus duplikat, nilai kosong), normalisasi teks, dan pembuatan kolom label (0/1).
- Menyiapkan format dataset untuk tokenizer/model (kolom text, label), serta menyimpan hasil skor prediksi.

b) NumPy

Dokumentasi resmi NumPy menyebut NumPy sebagai "paket fundamental" untuk komputasi ilmiah di Python [33]. Konsep inti NumPy adalah ndarray (N-dimensional array), yaitu kontainer multidimensi (umumnya berukuran tetap)

yang menampung item bertipe sama, dengan bentuk (*shape*) yang mendefinisikan ukuran tiap dimensi.
Dalam konteks ML/NLP, NumPy lazim dipakai untuk:

- Manipulasi vektor/array numerik (logits/probabilitas, thresholding).
- Perhitungan agregasi metrik sederhana, sampling, dan transformasi data.
- Menjadi basis interoperabilitas dengan pustaka lain (pandas, scikit-learn, *PyTorch*/TensorFlow pada beberapa tahap).

Dengan demikian, pandas/NumPy mendukung tahap "data engineering" pada pipeline moderasi: memastikan data komentar bersih, terstruktur, dan siap masuk ke proses tokenisasi serta pelatihan/evaluasi.

5) Scikit-learn (split, metrik evaluasi)

Scikit-learn adalah pustaka *machine learning* di Python yang menyediakan modul pemodelan klasik, *model selection*, serta *metrics* evaluasi yang luas.

a) Pembagian data (train/validation/test)

Dalam rancangan metodologi, dataset dibagi menjadi train/validation/test (70/15/15) dengan *stratified split* per label untuk menjaga proporsi kelas, terutama karena data komentar judi berpotensi tidak seimbang.

Implementasi stratified split umumnya memanfaatkan fungsi di ekosistem scikit-learn (bagian model selection) agar pembagian dataset lebih konsisten dan dapat direplikasi.

b) Metrik evaluasi klasifikasi

Evaluasi deteksi komentar promosi judi tidak cukup hanya akurasi; proposal menekankan perlunya *Precision*, *Recall*, F1-score, hingga PR-AUC untuk kondisi ketidakseimbangan kelas.

Secara definisi teknis, dokumentasi scikit-learn menjelaskan:

- *Precision* sebagai rasio tp / (tp + fp) dan *Recall* sebagai tp / (tp + fn).[34]
- F1-score sebagai rata-rata harmonik *Precision* dan *Recall*; nilainya terbaik 1 dan terburuk 0 [34].
- Confusion matrix sebagai matriks C dengan elemen C[i,j] menyatakan jumlah observasi kelas i yang diprediksi sebagai kelas j [34].

c) Implikasi ke desain moderasi

Pada sistem moderasi nyata, pemilihan metrik menentukan "gaya" keputusan moderasi:

- Jika tujuan utama meminimalkan komentar normal yang salah ditandai (false positive), desain akan mengejar *Precision* tinggi pada kelas "judi".
- Jika tujuan utama menangkap sebanyak mungkin komentar judi (minim false negative), desain akan mengejar *Recall* tinggi. Proposal sudah menekankan *trade-off* ini dan mengarah ke penggunaan F1/PR-AUC untuk menilai keseimbangan model.

6) Postman + Colab/Jupyter/VS Code

Bagian ini menjelaskan peran masing-masing alat dalam pengembangan dan pengujian sistem moderasi.

a) Postman (uji *endpoint*)

Postman umum dipakai untuk menguji layanan berbasis API karena menyediakan pengelolaan request (GET/POST), header, autentikasi, penyimpanan koleksi, dan eksekusi uji coba berulang. Dokumentasi resmi Postman menjelaskan Postman sebagai platform untuk membangun dan menggunakan API, termasuk pengujian API melalui koleksi dan request yang terstruktur [31]. (Jika pada implementasi sistem moderasi dibuat *endpoint* internal misalnya *endpoint* prediksi atau *endpoint* pemicu moderasi Postman membantu memastikan respons *endpoint* stabil sebelum diintegrasikan ke alur otomatis.)

b) Google Colab (komputasi notebook berbasis cloud)

Google Colab adalah lingkungan notebook berbasis cloud untuk menjalankan Python yang sangat sering dipakai untuk eksperimen ML/NLP (misalnya *fine-tuning*) karena memudahkan akses runtime dan akselerasi komputasi (tergantung ketersediaan). Dokumentasi resmi Colab menempatkannya sebagai lingkungan notebook yang dapat digunakan langsung melalui browser untuk menjalankan kode dan eksperimen berbasis Python [35]. Hal ini relevan untuk tahap pelatihan/*fine-tuning* model yang butuh komputasi

lebih berat.

c) VS Code (pengembangan kode terstruktur)

Visual Studio Code (VS Code) adalah editor/IDE ringan yang umum dipakai untuk pengembangan proyek Python karena dukungan ekstensi, debugging, dan manajemen proyek. Dokumentasi resmi VS Code menjelaskan VS Code sebagai editor kode yang mendukung produktivitas pengembangan melalui ekstensi dan fitur pengembangan modern [36]. Dalam proyek sistem moderasi, VS Code lebih cocok untuk pengembangan kode layanan (misalnya service inference, integrasi API, dan otomasi) dibanding notebook.

5. METODOLOGI PENELITIAN

a. Bahan Penelitian

1) Data Komentar Youtube
   - Sumber: komentar publik dari video yang mempunyai interaksi tinggi dan berpotensi memuat promosi judi.
   - Akses: diambil secara terprogram menggunakan *YouTube Data API v3* pada kanal/video yang diizinkan.
   - Batasan tindakan: aksi moderasi hanya dijalankan pada kanal yang memberikan otorisasi (*OAuth*) kepada peneliti.
   - Metadata minimal: commentId, videoId, authorDisplayName (opsional), *timestamp*, *parentId* (jika balasan), isi komentar mentah.
2) Dataset Latih-Uji (label biner)
   - Label:
     - Positif (1): komentar mengandung promosi judi (termasuk yang disamarkan/diobfusikasi).
     - Negatif (0): komentar tidak mengandung unsur judi.
   - Sumber Pembuatan:
     - Pengambilan komentar (lihat butir 1) pada rentang waktu tertentu.
     - Pelabelan manual oleh peneliti/asisten terlatih dengan

guideline yang jelas (contoh dan kontra-contoh).

- Resolusi konflik: bila ada perbedaan penilaian antar pelabel, gunakan *adjudication* singkat (diskusi atau *tie-breaker* oleh peneliti utama).

- Ketidakseimbangan kelas: tangani dengan class weighting saat pelatihan; *undersampling/oversampling* digunakan bila perlu.
- Pembagian data: train/validation/test (70/15/15) dengan *stratified split* per label.

3) Teks Tersandi (Tokenized Input)
   - Tokenizer: sesuai model dasar (*IndoBERT* / *IndoBERTweet*).
   - Normalisasi anti-obfusikasi (sebelum tokenisasi):
     - Pemetaan *leetspeak* (contoh: 4→a, 0→o, 1→i/l).
     - Penggabungan huruf terpisah: “s l o t” → “slot”.
     - Penyamaan penulisan merek/istilah judi yang umum.
     - *URL masking* (ganti URL dengan token khusus), penyaringan *emoji* dan karakter mirip (*confusables*) bila mengganggu.
   - Model dasar: *IndoBERT* / *IndoBERTweet* untuk bahasa Indonesia; *bert-base-uncased* dipakai sebagai pembanding.

b. Alat Penelitian

1) Perangkat Keras
   - Minimal: prosesor setara Intel Core i3, RAM 8 GB, penyimpanan 256 GB.
   - Penyimpanan: direktori terstruktur untuk data mentah, data bersih, model, dan *logs*.
2) Bahasa : Python 3.x.
3) Pustaka Utama:
   - *Transformers* (Hugging Face) untuk model *BERT*.
   - *PyTorch* atau *TensorFlow* untuk pelatihan.
   - *scikit-learn* untuk metrik dan *split*.

- *pandas* dan *NumPy* untuk olah data.

4) API & alat bantu:
   - *YouTube Data API v3* (kunci API & *OAuth*).
   - *Postman* (opsional) untuk uji *endpoint*.
5) Lingkungan kerja: Google Colab / Jupyter Notebook / VS Code.
6) Manajemen eksperimen: pencatatan *hyperparameter*, versi dataset, dan hasil metrik agar replikasi mudah.

c. Alur Penelitian

1) Tahap 1 Pengumpulan Data Komentar
   - Menetapkan daftar video target (populer/berisiko tinggi muncul promosi judi).
   - Mengambil komentar dan balasan terbaru menggunakan *endpoint* pengambilan komentar.
   - Menyimpan komentar dan metadata minimal ke berkas *CSV/JSON*; hindari menyimpan data pribadi yang tidak diperlukan.
   - Menjaga *rate limit* dan *quota* API agar stabil.

   Keluaran: komentar mentah + metadata
2) Tahap 2 Pembersihan & Pelabelan
   - Menyaring komentar kosong/duplikat/berulang.
   - Menyusun *guideline* pelabelan (definisi "promosi judi", contoh kata kunci, contoh obfusikasi).
   - Melabeli komentar: 1 (promosi judi) atau 0 (bukan).
   - Audit kualitas label (cek konsistensi; selesaikan konflik).
   - Membagi data *train/validation/test* dengan *stratified split*.

   Keluaran: dataset terlabel siap latih-uji
3) Tahap 3 Praproses & Tokenisasi
   - Normalisasi anti-obfusikasi: Pemetaan huruf–angka, penggabungan huruf terpisah, *URL masking*, penyelarasan istilah.
   - *Lowercasing* bila model mengizinkan; bersihkan karakter yang mengganggu.

- Tokenisasi sesuai *tokenizer* model (maks panjang sekuens ditentukan pada eksperimen).

Keluaran : pasangan (input ids, *attention mask,* label)

4) Tahap 4 Pelatihan Model Deteksi
   - Memilih model dasar: *IndoBERT* / *IndoBERTweet*; menyiapkan baseline pembanding (*bert-base-uncased*).
   - Menetapkan *hyperparameter* awal: *learning rate*, ukuran *batch*, jumlah *epoch*, panjang sekuens, *class weight*.
   - *Fine-tuning* pada data latih; memantau *loss* validasi dan menghentikan dini (*early stopping*) jika perlu.
   - Menyimpan model terbaik berdasarkan skor *F1* pada data validasi.

   Keluaran : model terlatih + konfigurasi terbaik

5) Tahap 5 Evaluasi Offline
   - Menguji model pada test set yang tidak dilihat saat pelatihan.
   - Menghitung metrik: akurasi, *Precision*, *Recall*, *F1-score* (utamanya *F1* kelas positif), serta *confusion matrix*.
   - Analisis kesalahan: contoh *false positive*/*false negative*, terutama kasus obfusikasi yang lolos.
   - (Opsional) *Ablation study*: tanpa normalisasi, tanpa daftar kata kunci, atau mengganti model dasar → untuk melihat komponen yang paling berpengaruh.

   Keluaran : metrik kinerja + temuan analisis

6) Tahap 6 Integrasi Model dengan Sistem Moderasi
   - Menyiapkan layanan inferensi sederhana (*service* lokal atau *notebook*) yang menerima teks komentar → mengembalikan skor pelanggaran.
   - Menetapkan ambang keputusan (threshold) berdasarkan kurva *Precision–Recall* pada data validasi:
     - Tahan (hold) bila skor ≥ ambang tinggi (prioritaskan *Precision*).

    - Tolak bila skor sangat tinggi (opsional, setelah uji lebih lanjut).
    - Lolos bila skor < ambang.
  - Menghubungkan layanan inferensi dengan alur pengambilan komentar → menjalankan tindakan moderasi otomatis pada kanal berotorisasi.

  Keluaran: *pipeline* moderasi proaktif siap uji

7) Tahap 7 Pengujian Sistem *(near real-time)*
  - Menjalankan *pipeline* pada video target selama periode uji (1–3 bulan).
  - Mencatat: waktu datang komentar → waktu keputusan (latensi), jumlah komentar yang ditahan/ditolak, serta sampel *false positive/false negative*.
  - Menyiapkan *dashboard* sederhana (log/rekap harian) untuk memantau stabilitas.

  Keluaran: log operasional dan ringkasan kinerja *online.*

8) Tahap 8 Analisis & Perbaikan
  - Membandingkan hasil *online* dengan uji *offline* (apakah terjadi perbedaan besar).
  - Menyetel ulang ambang (bila *false positive* tinggi) atau menambah aturan pasca-model (daftar kata *high-Precision*).
  - Menentukan versi model final untuk dilaporkan.

  Keluaran: model final + parameter operasional

9) Tahap 9 Dokumentasi & Penulisan Laporan
  - Mendokumentasikan: struktur data, *preprocessing*, konfigurasi pelatihan, metrik, dan arsitektur integrasi.
  - Menyusun bab hasil, pembahasan, kesimpulan, dan saran pengembangan.
  - Menyimpan *artefact* (dataset teranotasi, *script* eksperimen, *weights* model) sesuai kebijakan kampus/etika data.

6. JADWAL PENELITIAN

No.	Kegiatan	Bulan 1				Bulan 2				Bulan 3				Bulan 4			
		1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
1	Perencanaan penelitian (penetapan ruang lingkup, target kanal/video, kebutuhan data, dan rencana kerja	×	×														
2	Studi literatur dan penguatan landasan teori (NLP/Transformer, deteksi spam, moderasi komentar, dan API)	×	×	×													
3	Persiapan lingkungan pengembangan (tools, repository, struktur data, dan pencatatan eksperimen/log)		×	×													
4	Konfigurasi dan verifikasi akses YouTube Data API v3 (OAuth, uji endpoint, dan validasi respons)			×	×												
5	Implementasi modul akuisisi data komentar (paginasi, batching, penyimpanan terstruktur)				×	×											

No.	Kegiatan	Bulan 1				Bulan 2				Bulan 3				Bulan 4			
		1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
6	Akuisisi dataset komentar (pengumpulan data sesuai kriteria dan dokumentasi sumber)					×	×										
7	Kurasi dataset (pembersihan data, deduplikasi, penanganan data kosong/noise)					×	×										
8	Penyusunan pedoman pelabelan dan skema kelas (definisi label, contoh, serta aturan pelabelan)					×	×										
9	Pelabelan data dan pemeriksaan konsistensi (audit sampel, perbaikan ketidakkonsistenan)						×	×	×								
10	Pembagian dataset (train/validation/test) secara terstratifikasi dan finalisasi format data							×	×								
11	Praproses teks dan penanganan obfuscation (normalisasi, masking, dan tokenisasi)								×	×							

No.	Kegiatan	Bulan 1				Bulan 2				Bulan 3				Bulan 4			
		1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
12	Pelatihan model (fine-tuning) dan penalaan parameter (hyperparameter tuning)									×	×						
13	Evaluasi performa model (metrik klasifikasi, analisis kesalahan, pemilihan model terbaik)										×	×					
14	Pengembangan layanan inferensi berbasis API (endpoint prediksi, autentikasi sederhana, logging)											×	×				
15	Perancangan dan implementasi dashboard moderasi (UI list komentar, filter, detail, status, dan kontrol aksi)												×	×	×		
16	Integrasi dashboard–API–YouTube (aksi hold/reject/approve) dan pengujian fungsional end-to-end														×	×	

No.	Kegiatan	Bulan 1				Bulan 2				Bulan 3				Bulan 4			
		1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
17	Pengujian near real-time dan evaluasi operasional (latensi, stabilitas, sampling FP/FN, penetapan ambang/threshold)															×	
18	Penyusunan laporan skripsi dan dokumentasi sistem (hasil, pembahasan, kesimpulan, lampiran, dan revisi)									×	×	×	×	×	×	×	×

Tabel 2 Jadwal Penelitian

7. DAFTAR PUSTAKA

[1] Shubham Singh, "How Many People Use YouTube in 2025 [Active Users Data]." Accessed: Apr. 20, 2025. [Online]. Available: https://www.demandsage.com/youtube-stats/

[2] S. Kemp, "YouTube Users, Stats, Data & Trends for 2025." Accessed: Nov. 05, 2025. [Online]. Available: https://datareportal.com/essential-youtube-stats

[3] S. Kemp, "Digital 2024: Indonesia." Accessed: Nov. 05, 2025. [Online]. Available: https://datareportal.com/reports/digital-2024-indonesia

[4] S. Kemp, "Digital 2025: Indonesia." Accessed: Nov. 05, 2025. [Online]. Available: https://datareportal.com/reports/digital-2025-indonesia

[5] Youtube, "Youtube Help : Spam, deceptive practices, & scams policies." Accessed: Nov. 05, 2025. [Online]. Available: https://support.google.com/youtube/answer/2801973?hl=en

[6] K. Taha, P. D. Yoo, C. Yeun, D. Homouz, and A. Taha, "A comprehensive survey of text classification techniques and their research applications: Observational and experimental insights," *Comput. Sci. Rev.*, vol. 54, p. 100664, Nov. 2024, doi: 10.1016/j.cosrev.2024.100664.

[7] S. Alshattnawi, A. Shatnawi, A. M. R. AlSobeh, and A. A. Magableh, "Beyond Word-Based Model Embeddings: Contextualized Representations for Enhanced Social Media Spam Detection," *Applied Sciences (Switzerland)*, vol. 14, no. 6, Mar. 2024, doi: 10.3390/app14062254.

[8] G. Airlangga, "Spam Detection on YouTube Comments Using Advanced Machine Learning Models: A Comparative Study," *Brilliance: Research of Artificial Intelligence*, vol. 4, no. 2, pp. 500–508, Oct. 2024, doi: 10.47709/brilliance.v4i2.4670.

[9] E. Smith, N. Reiter, and J. Peters, "Automatic detection of problem-gambling signs from online texts using large language models," Nov. 2023, [Online]. Available: http://arxiv.org/abs/2312.00804

[10] Google Developer, "YouTube Data API v3 || Comments: setModerationStatus | CommentThreads | Kuota." Accessed: Apr. 20, 2025. [Online]. Available: https://developers.google.com/youtube/v3/docs/comments/setModerationStatus

[11] Google Developer, "Google API Client (Java) || YouTube Data API v3 (revision 222)." Accessed: Nov. 05, 2025. [Online]. Available: https://developers.google.com/resources/api-libraries/documentation/youtube/v3/java/latest/com/google/api/services/youtube/YouTube.Comments.SetModerationStatus

[12] Ed. D. Hardt, "The OAuth 2.0 Authorization Framework," 2012, [Online]. Available: http://www.rfc-editor.org/info/rfc6749.

[13] A. , & S. R. KhudaBukhsh, "Why a Youtube Chat about Chess Got Flagged for Hate Speech." Accessed: Apr. 20, 2025. [Online]. Available: https://www.wired.com/story/why-youtube-chat-chess-flagged-hate-

speech/

[14] M. Zulqarnain, R. Ghazali, Y. M. M. Hassim, and M. Rehan, "A comparative review on deep learning models for text classification," *Indonesian Journal of Electrical Engineering and Computer Science*, vol. 19, no. 1, pp. 325–335, 2020, doi: 10.11591/ijeecs.v19.i1.pp325-335.

[15] M. Sam'an and K. Imaddudin, "Hybrid deep learning model for YouTube spam comment detection," *International Journal of Electrical and Computer Engineering*, vol. 14, no. 3, pp. 3313–3319, Jun. 2024, doi: 10.11591/ijece.v14i3.pp3313-3319.

[16] C. Eang and S. Lee, "Improving the Accuracy and Effectiveness of Text Classification Based on the Integration of the Bert Model and a Recurrent Neural Network (RNN_Bert_Based)," *Applied Sciences (Switzerland)*, vol. 14, no. 18, Sep. 2024, doi: 10.3390/app14188388.

[17] F. Koto, A. Rahimi, J. H. Lau, and T. Baldwin, "IndoLEM and IndoBERT: A Benchmark Dataset and Pre-trained Language Model for Indonesian NLP," Online. [Online]. Available: https://huggingface.co/

[18] F. Koto Jey Han Lau Timothy Baldwin, "INDOBERTWEET: A Pretrained Language Model for Indonesian Twitter with Effective Domain-Specific Vocabulary Initialization." [Online]. Available: https://huggingface.co/huseinzol05/

[19] A. Al Farizi, G. B. Soesilo, and A. R. Sasmita, "Analisis Kriminologi terhadap Promosi Judi Online di Media Sosial dalam Perspektif Hukum Pidana History Abstrak," 2025.

[20] N. F. Juhara, M. Amalia, and A. Mulyana, "Efektivitas Penegakan Hukum terhadap Judi Online di Indonesia: Analisis Yuridis dan Sosiologis," *Journal of Contemporary Law Studies*, vol. 2, no. 2, pp. 153–164, Feb. 2025, doi: 10.47134/lawstudies.v2i2.3353.

[21] S. H. Renata Christha Auli, "Hukum Judi Online, ini aturan terbarunya!" Accessed: Dec. 15, 2025. [Online]. Available: https://www.hukumonline.com/klinik/a/hukum-judi-online-ini-aturan-

terbarunya%2521-cl7026/

[22] L. Kristianti, “Menkominfo: Judi online adalah penipuan yang perlu diberantas,” Jul. 25, 2024. Accessed: Dec. 15, 2025. [Online]. Available: https://www.antaranews.com/berita/4216659/menkominfo-judi-online-adalah-penipuan-yang-perlu-diberantas

[23] F. Jauhari, M. Riza, R. G. Guntara, and M. R. Nugraha, “Implementasi Algoritma Naive Bayes untuk Filtrasi Spam Komentar Judi Online pada YouTube,” 2025. [Online]. Available: https://ejournal.upi.edu/index.php/IJDB

[24] A. S. Xiao and Q. Liang, “Spam detection for Youtube video comments using machine learning approaches,” *Machine Learning with Applications*, vol. 16, p. 100550, Jun. 2024, doi: 10.1016/j.mlwa.2024.100550.

[25] A. Vaswani *et al.*, “Attention Is All You Need,” 2023.

[26] A. Ghiffari and P. Hendradi, “Implementasi Single sign on (SSO) Menggunakan Representational State Transfer (REST) dan Open Authorization (OAuth 2.0) (Studi kasus: Universitas Muhammadiyah Magelang).”

[27] Python Software Foundation, “Python Documentation.” Accessed: Jan. 04, 2026. [Online]. Available: https://docs.python.org/3/faq/general.html#what-is-python

[28] T. Wolf *et al.*, “HuggingFace’s Transformers: State-of-the-art Natural Language Processing,” Jul. 2020, [Online]. Available: http://arxiv.org/abs/1910.03771

[29] “Hugging Face - Transformers Documentation.” Accessed: Jan. 04, 2026. [Online]. Available: https://huggingface.co/docs/transformers

[30] PyTorch, “PyTorch Documentation.” Accessed: Jan. 04, 2026. [Online]. Available: https://docs.pytorch.org/tutorials/beginner/basics/autogradqs_tutorial.html

[31] Tensorflow, “Tensorflow Documentation - Model Keras .” Accessed:

Jan. 04, 2026. [Online]. Available: https://www.tensorflow.org/api_docs/python/tf/keras/Model

[32] Pandas, “Pandas Documentation.” Accessed: Jan. 04, 2026. [Online]. Available: https://pandas.pydata.org/docs/

[33] NumPy, “NumPy Documentation.” Accessed: Jan. 04, 2026. [Online]. Available: https://numpy.org/doc/stable/index.html

[34] Scikit-learn Developers, “Scikit Learn Metrics API.” Accessed: Jan. 04, 2026. [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.precision_recall_fscore_support.html

[35] Google Developers, “Colaboratory.” Accessed: Jan. 04, 2026. [Online]. Available: https://developers.google.com/colab?utm_source=chatgpt.com

[36] Visual Studio team, “Visual Studio Code.” Accessed: Jan. 04, 2026. [Online]. Available: https://code.visualstudio.com/Docs

8. LAMPIRAN

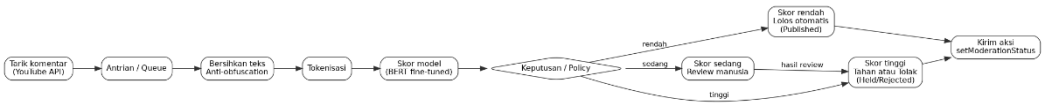

Gambar 1 Alur Proses Moderasi

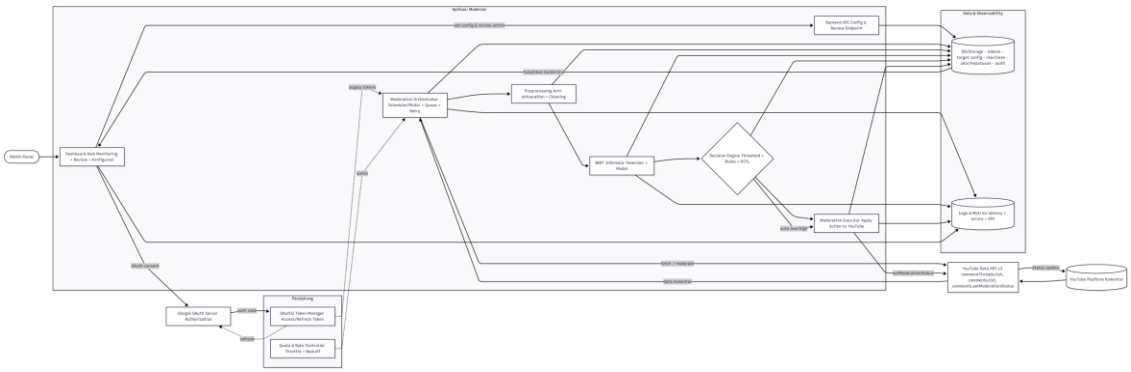

Gambar 2 Arsitektur Sistem

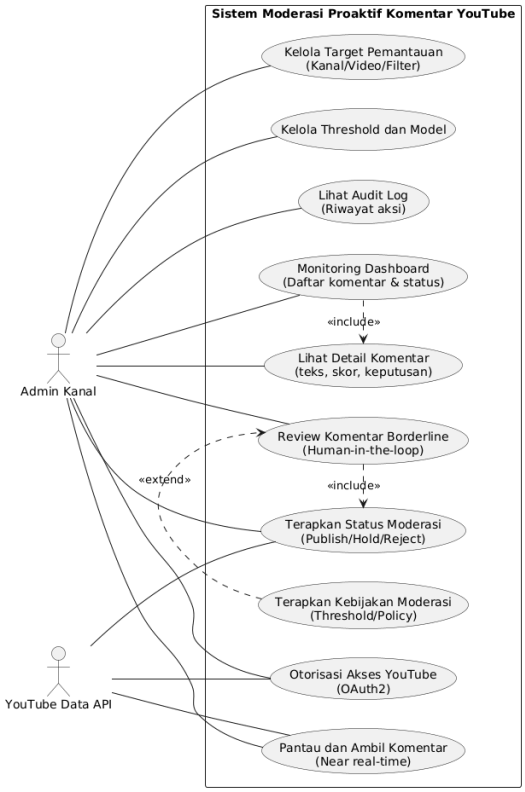

Gambar 3 Use Case Diagram

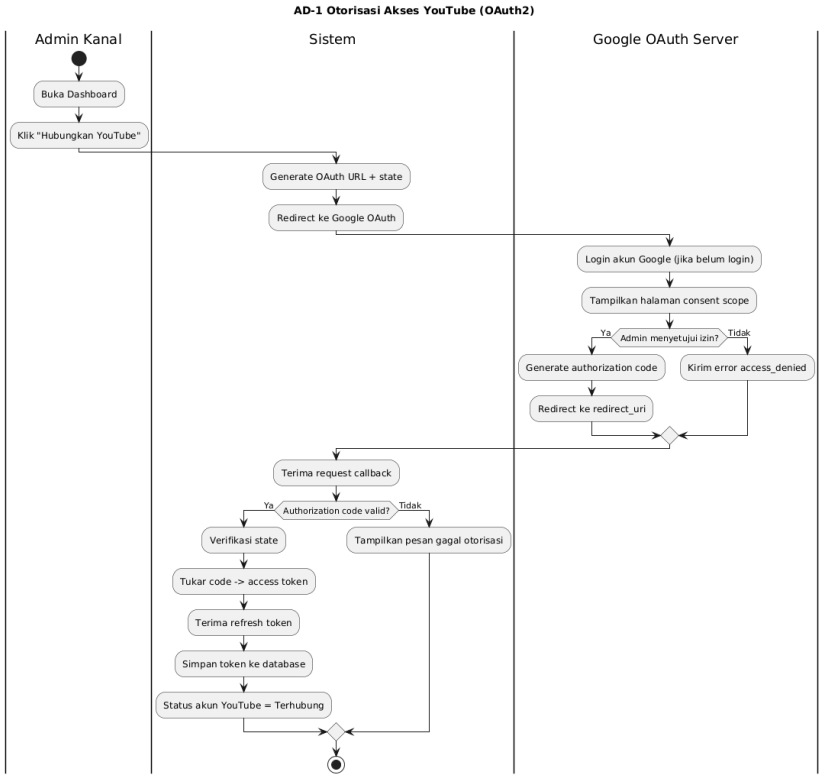

Gambar 4 AD - 1 Otorisasi Akses Youtube

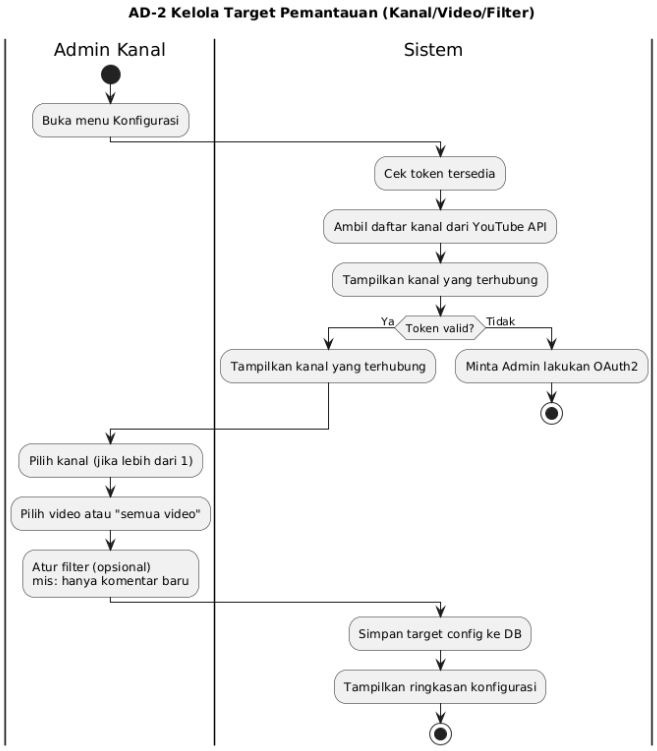

Gambar 5 AD – 2 Kelola Target Pemantauan

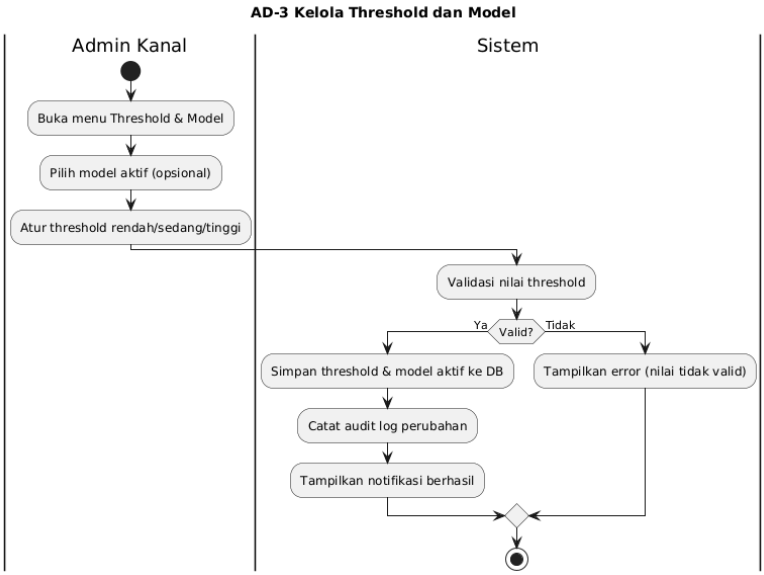

Gambar 6 AD – 3 Kelola Threshold

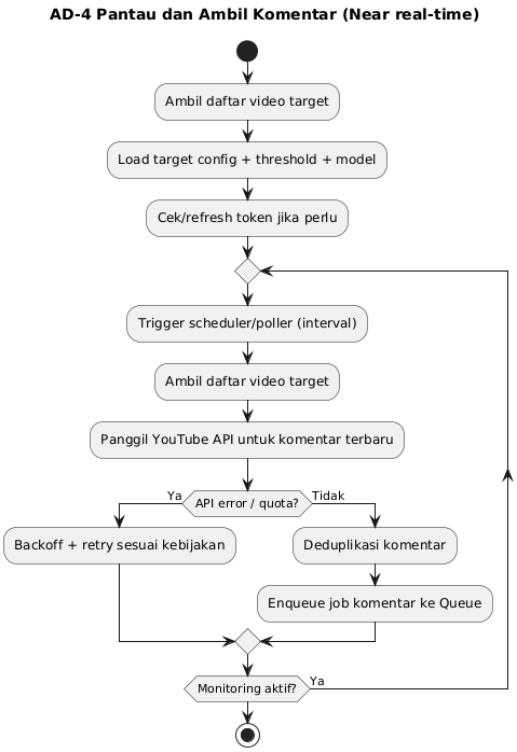

Gambar 7 AD – 4 Pantau dan ambil komentar (Near Real-time)

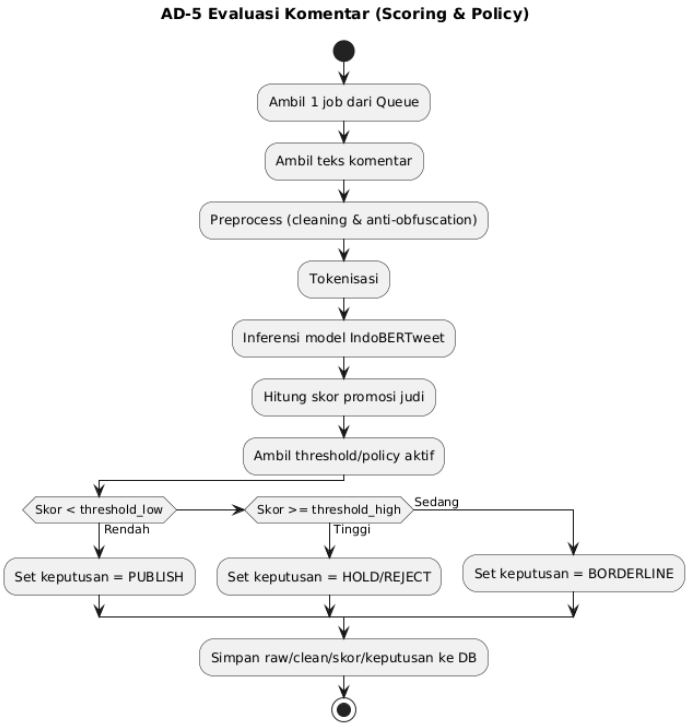

Gambar 8 AD - 5 Evaluasi Komentar (scoring & policy)

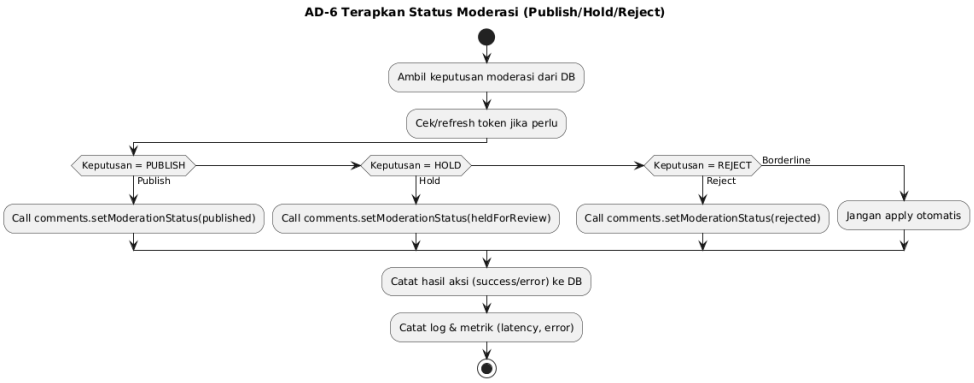

Gambar 9 AD - 6 Terapkan Status Moderasi (Publish,Hold,Reject)

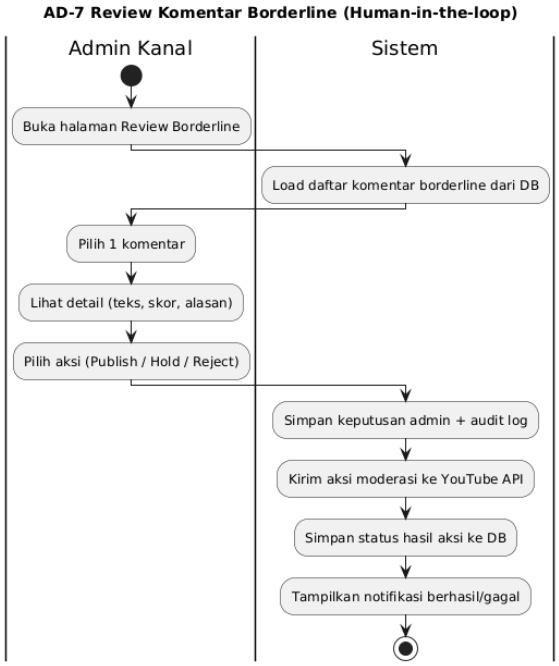

Gambar 10 AD – 7 Review Komentar Borderline (Human-in-the-loop)

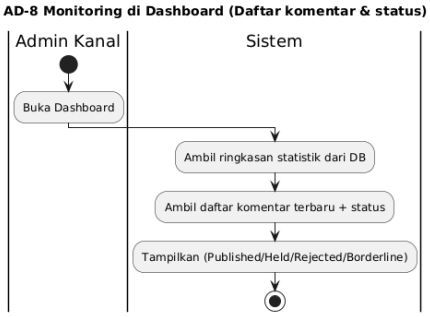

Gambar 11 AD - 8 Monitoring di Dashboard (Daftar komentar & status)

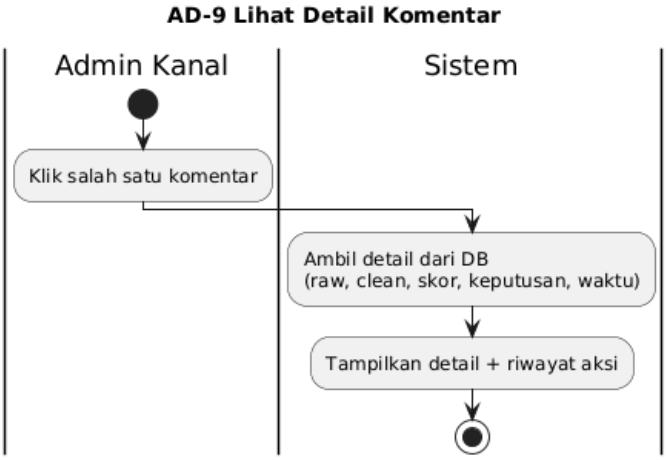

Gambar 12 AD - 9 Lihat Detail Komentar

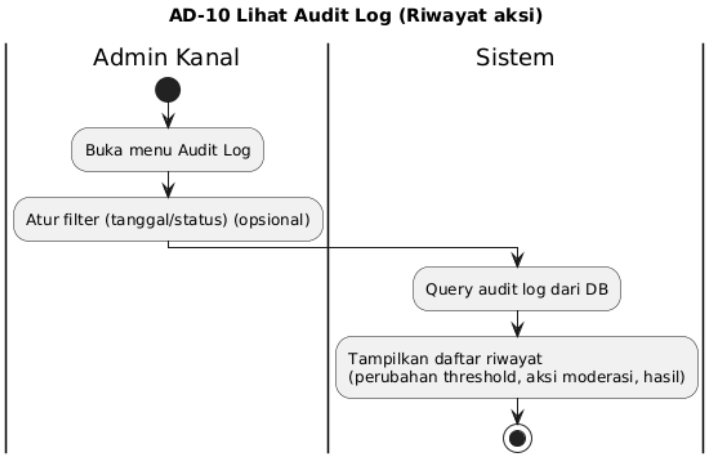

Gambar 13 AD - 10 Lihat Audit Log (Riwayat aksi)

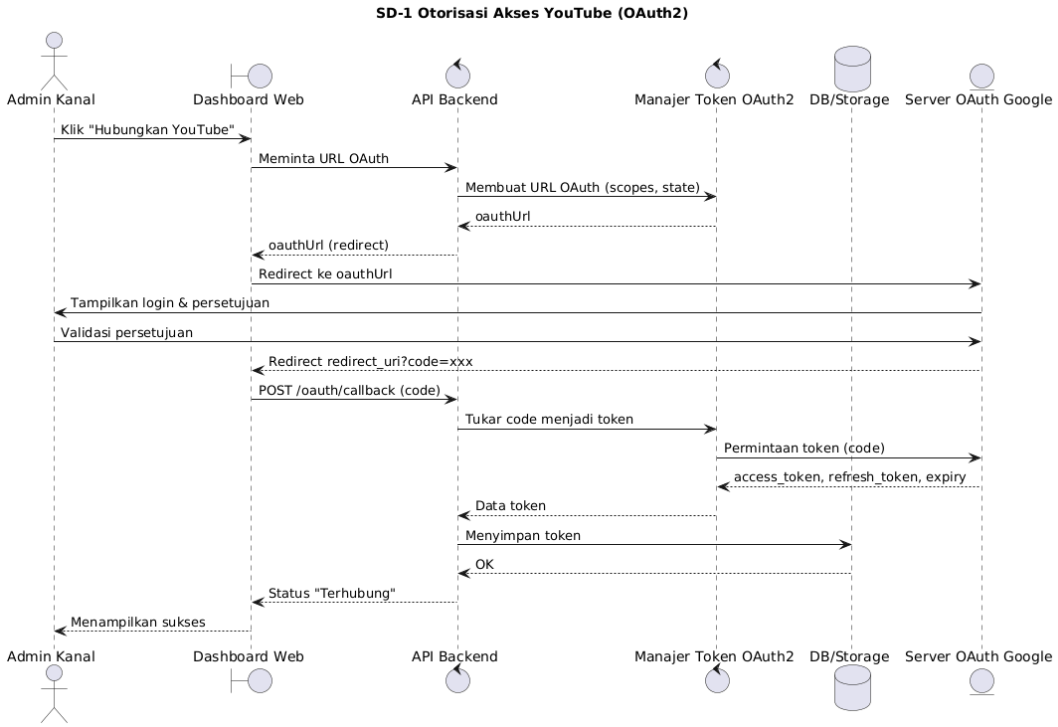

Gambar 14 SD-1 Otorisasi Akses YouTube (OAuth2)

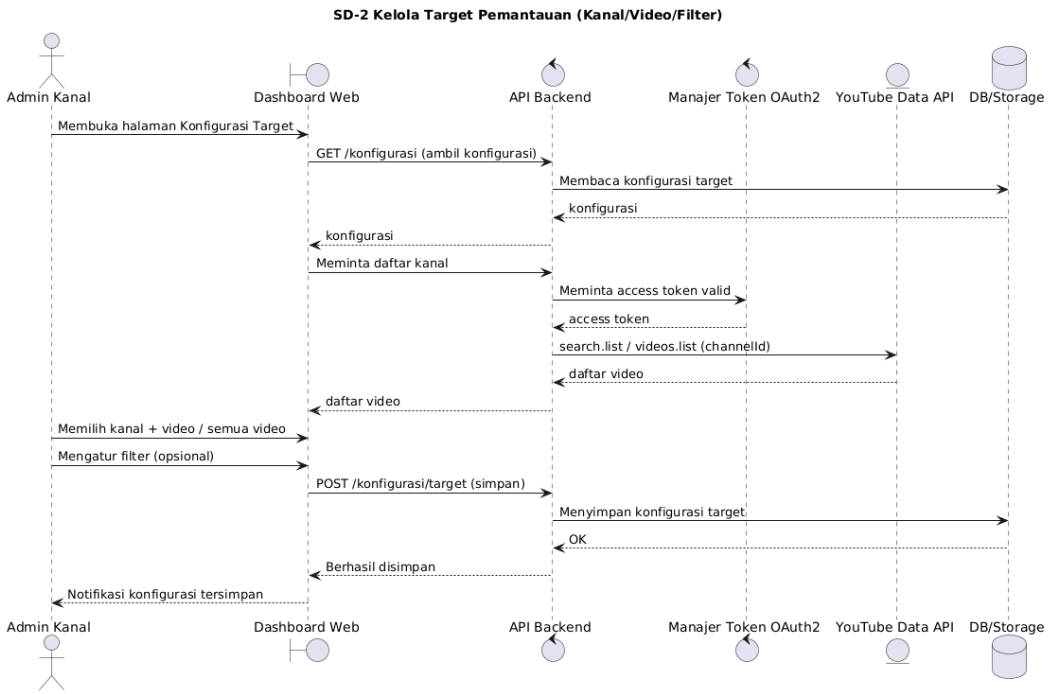

Gambar 15 SD-2 Kelola Target Pemantauan (Kanal,Video,Filter)

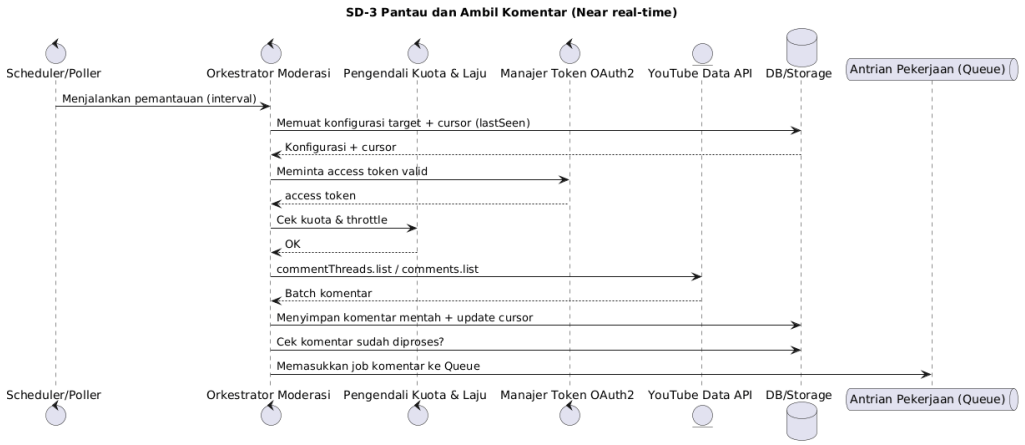

Gambar 16 SD-3 Pantau dan Ambil Komentar (Near real-time)

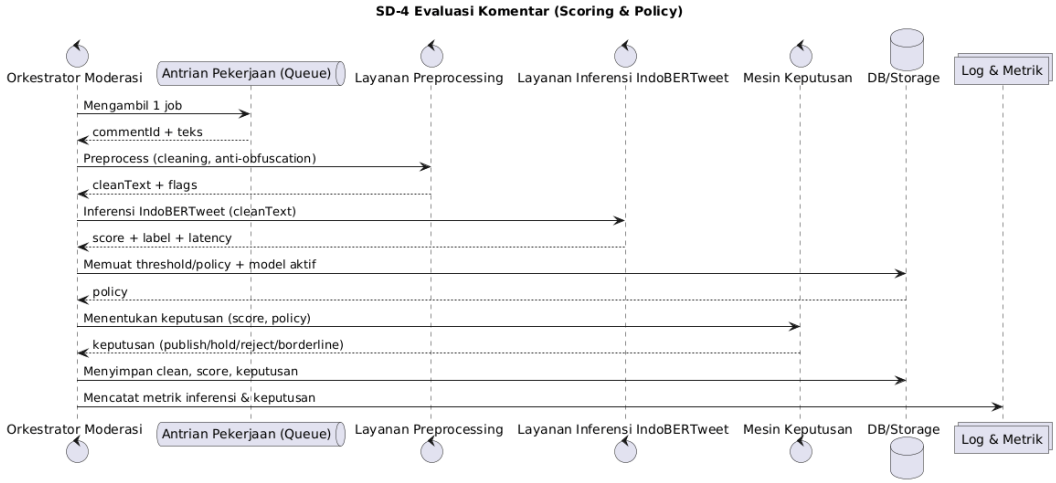

Gambar 17 SD-4 Evaluasi Komentar (Scoring & Policy)

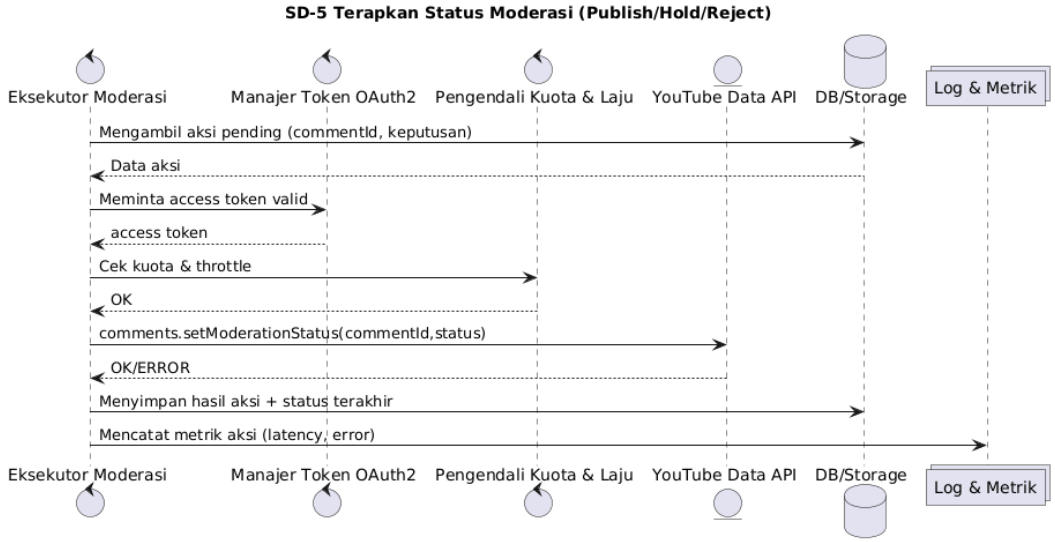

Gambar 18 SD-5 Terapkan Status Moderasi (Publish,Hold,Reject)

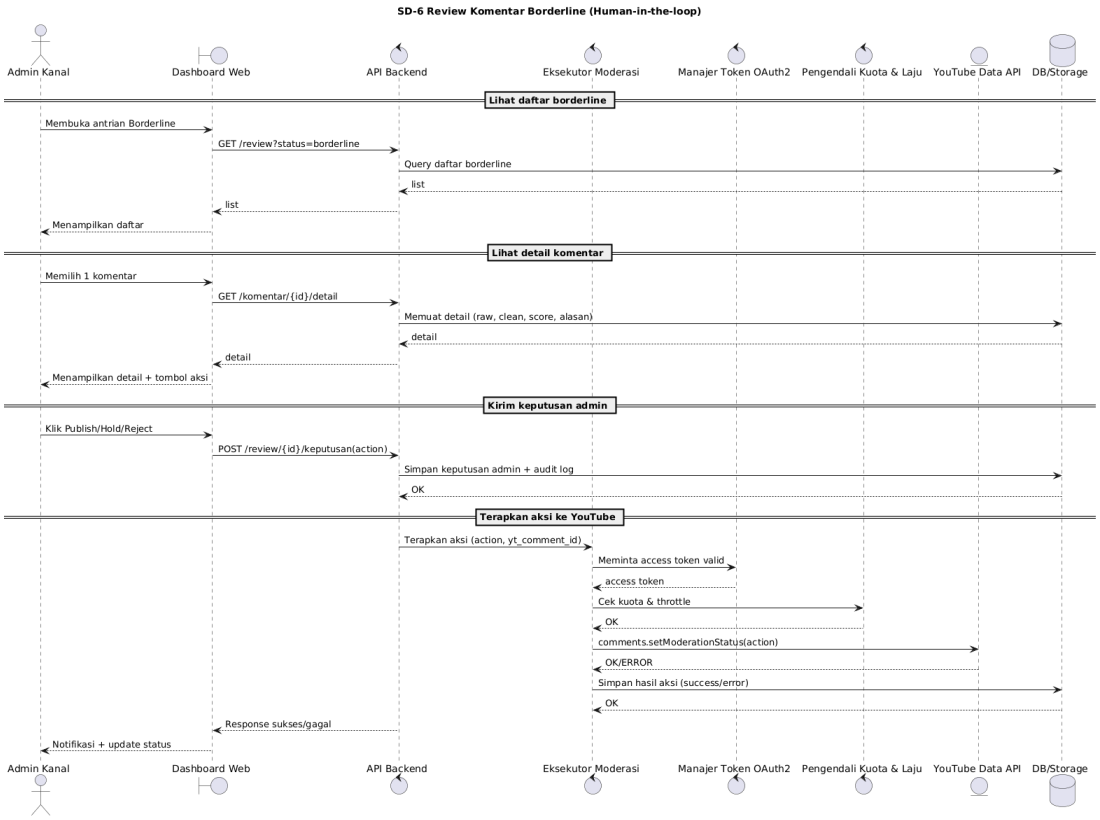

Gambar 19 SD-6 Review Komentar Borderline (Human-in-the-loop)

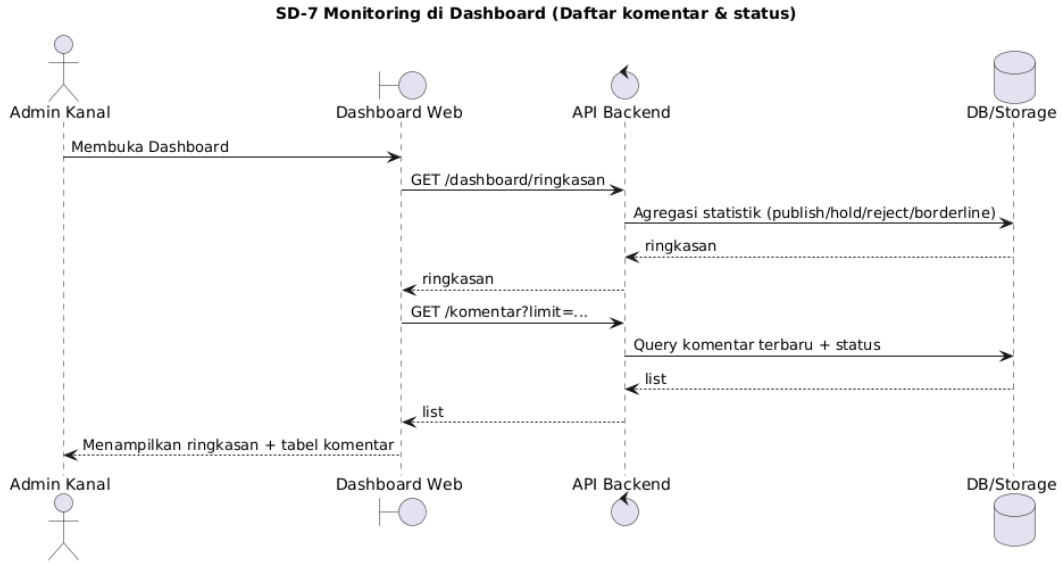

Gambar 20 SD-7 Monitoring di Dashboard (Daftar komentar & status)

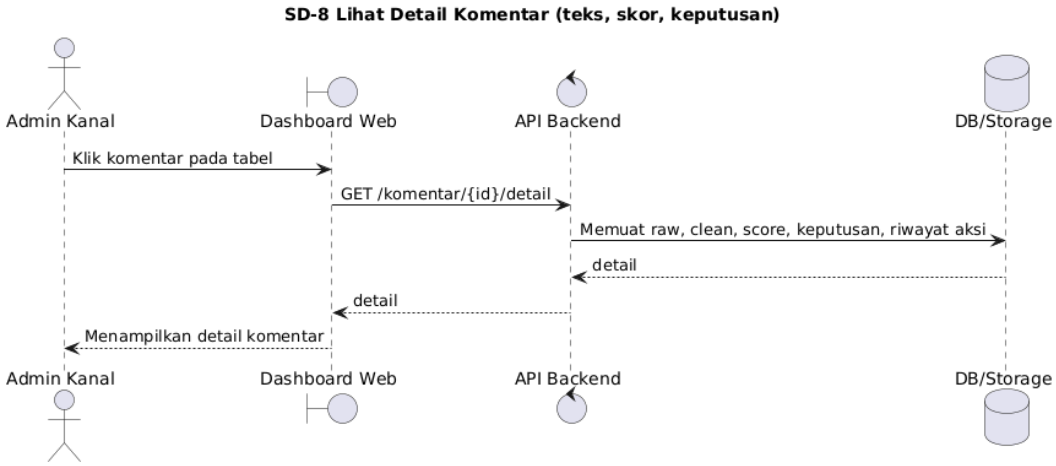

Gambar 21 SD-8 Lihat Detail Komentar (teks, skor, keputusan)

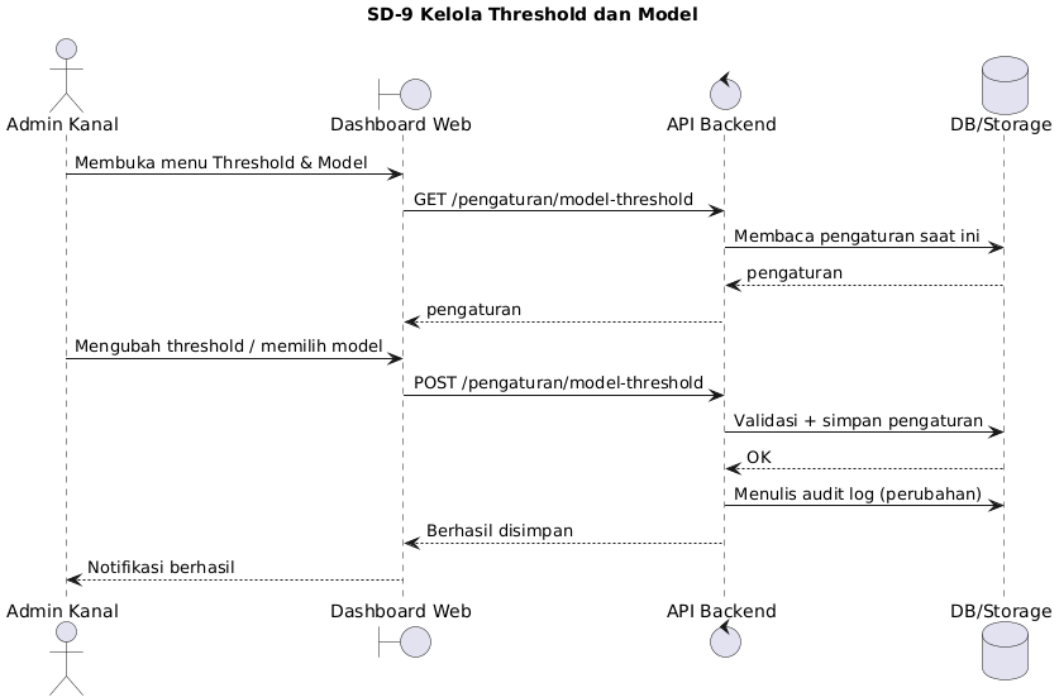

Gambar 22 SD-9 Kelola Threshold dan Model

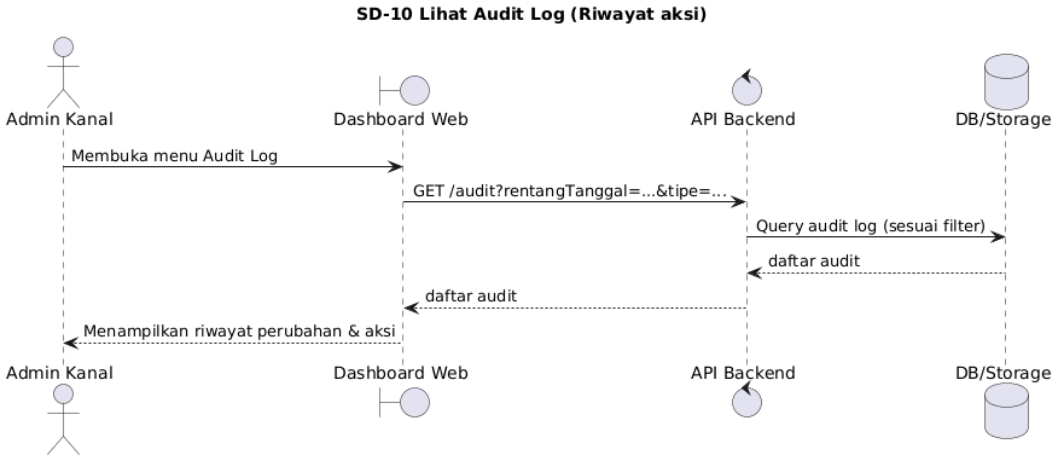

Gambar 23 SD-10 Lihat Audit Log (Riwayat aksi)

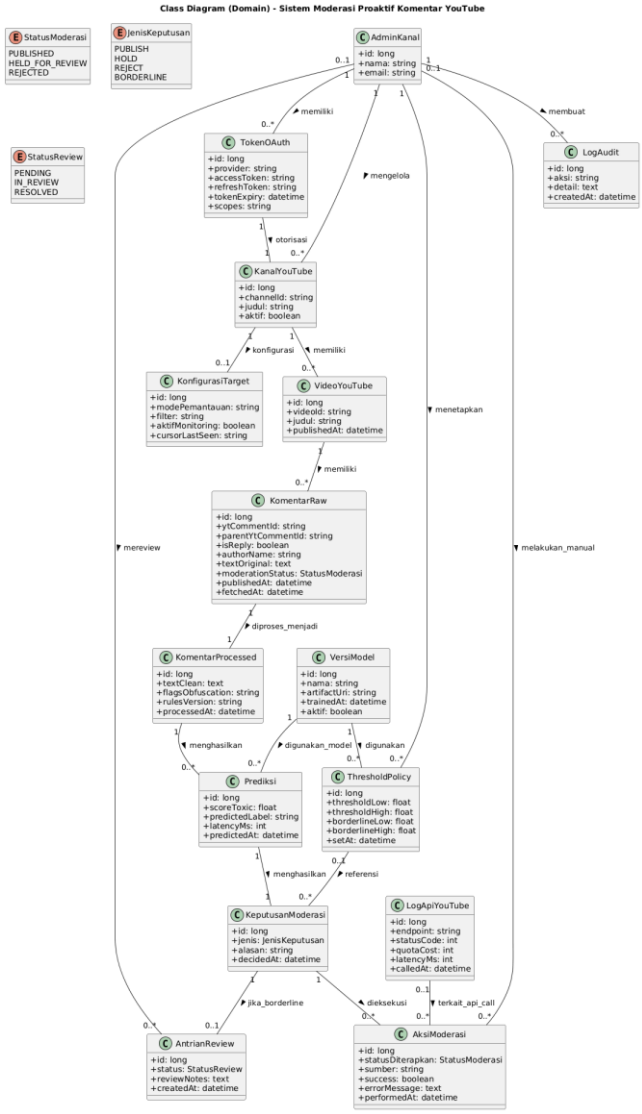

Gambar 24 Class Diagram

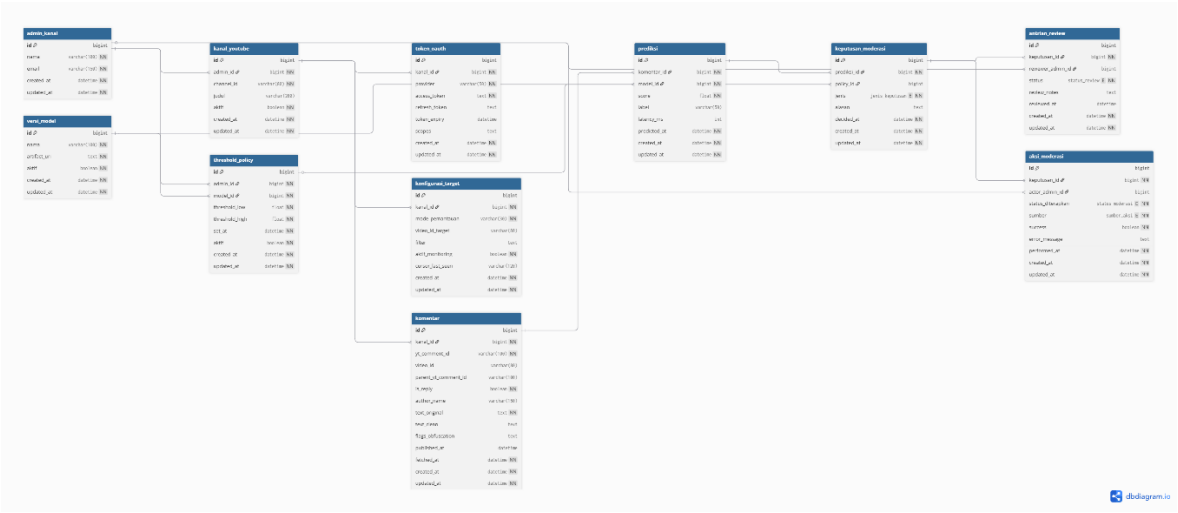

Gambar 25 Desain Database

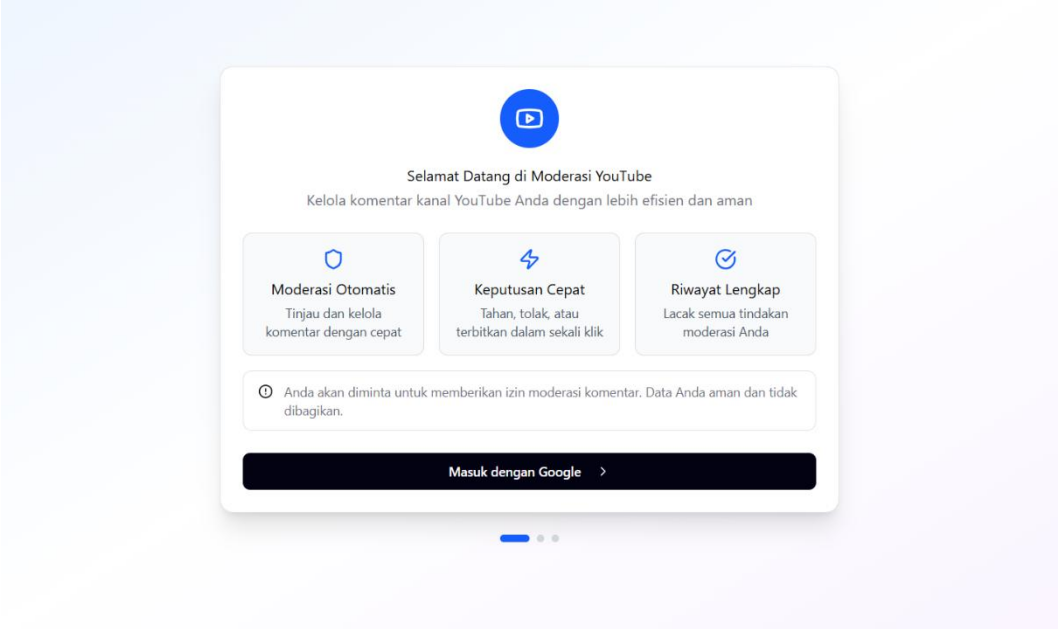

Gambar 26 UI/UX Login Page

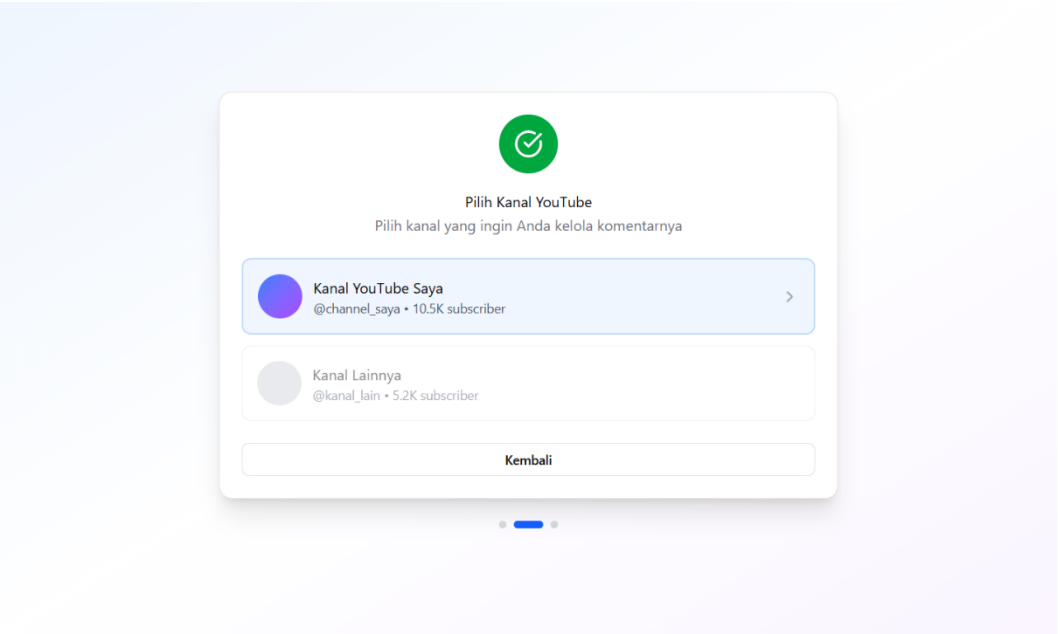

Gambar 27 UI/UX Pilih Kanal

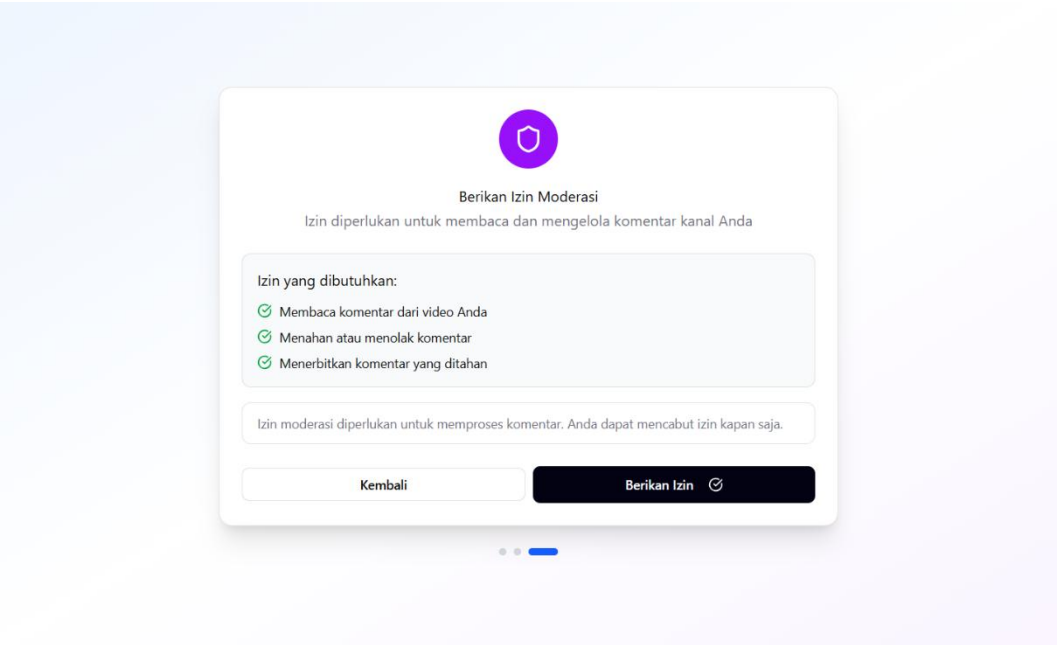

Gambar 28 UI/UX Verifikasi Izin

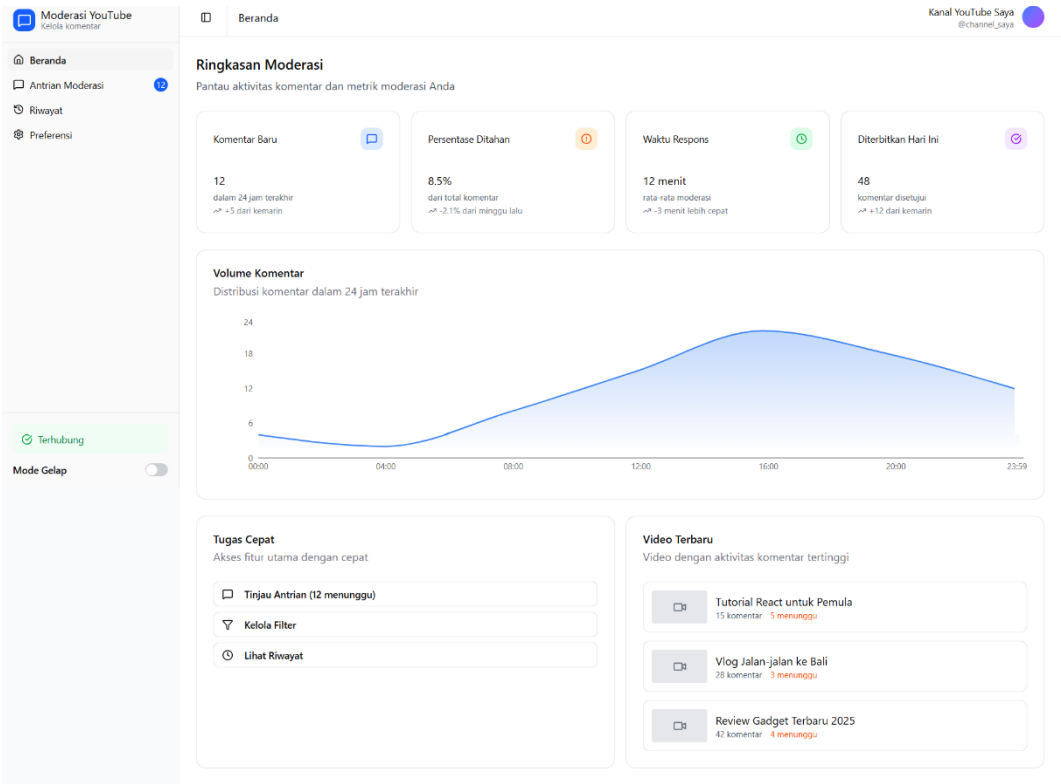

Gambar 29 UI/UX Dashboard

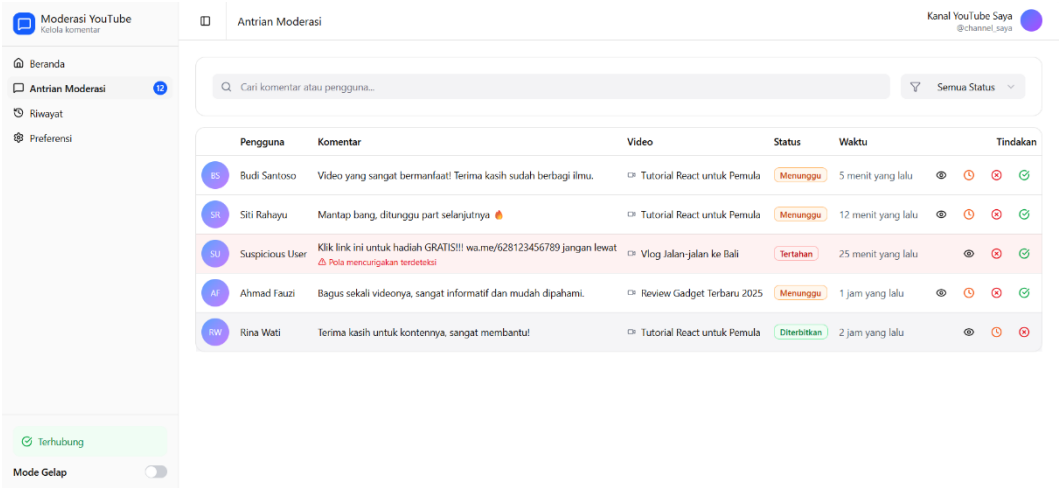

Gambar 30 UI/UX Halaman Moderasi

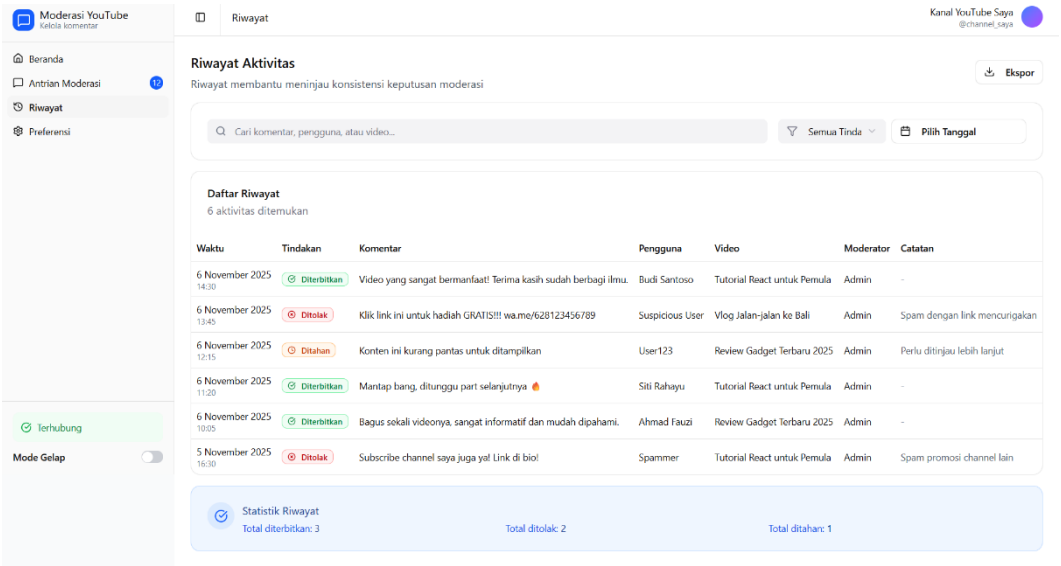

Gambar 31 UI/UX Halaman Riwayat

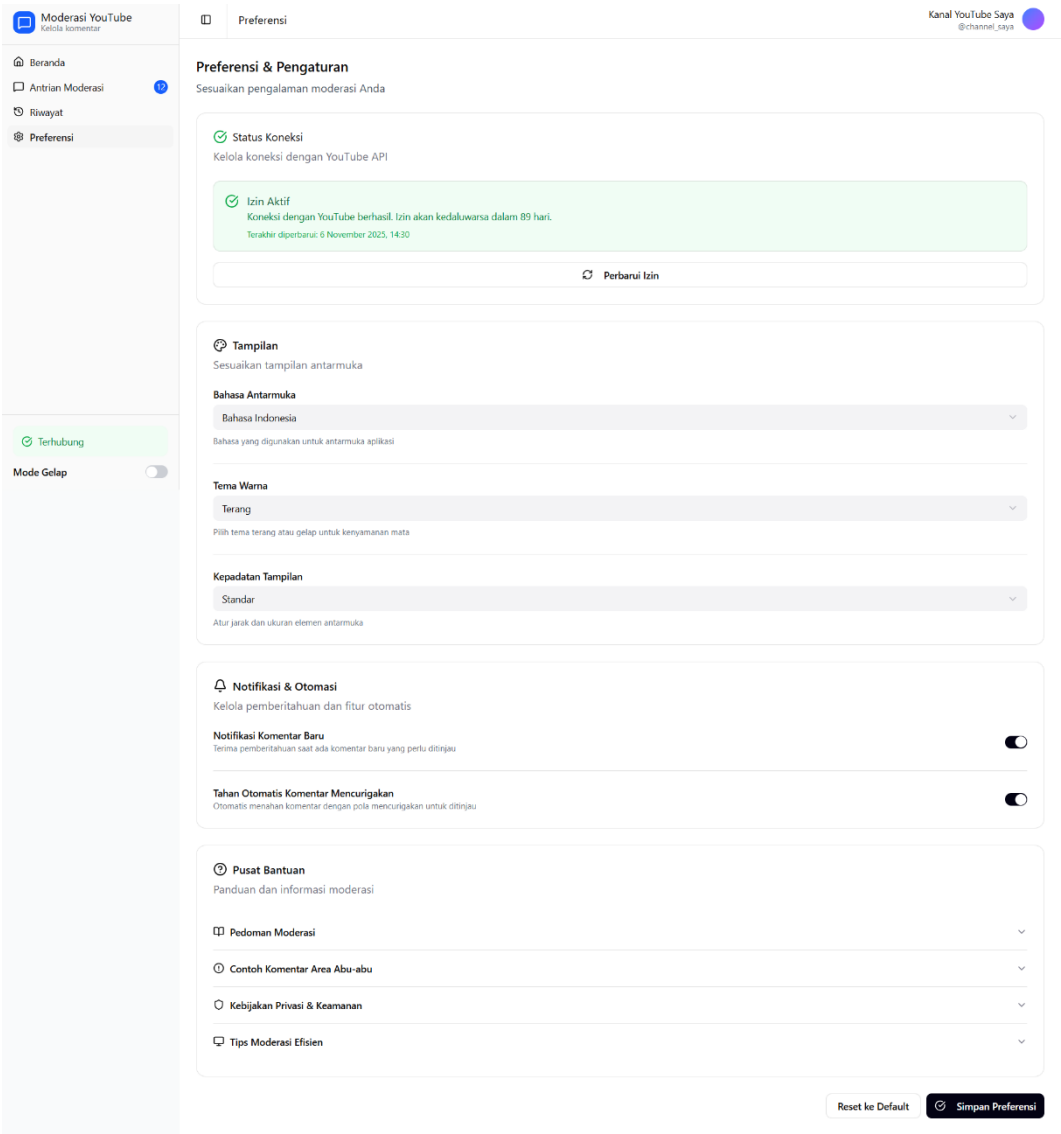

Gambar 32 UI/UX Halaman Pengaturan